Orientation et tri multimodal des demandeurs d'emploi par l'Intelligence Artificielle

For external use

14/10/2026 à 12h

Dans le cadre la certification Atlas :
« Concevoir et implémenter une solution d'intelligence artificielle (IA) »

Sommaire

1. Cadrage métier & problème
2. Sources des données
3. Exploration & analyse des données
4. Préparation des données et scénarios de jeux de données
5. Modélisation & entrainement
6. Analyse des scénarios & arbitrage
7. Interprétation client
8. Industrialisation
9. Suivi en production & amélioration continue
10. Conclusion et questions ouvertes

01

Cadrage métier & problème

Cadrage métier & problème

Quel est le problème ? Comment le résoudre ?



Contexte client

- Agence nationale de l'emploi / service public
- Problème métier : orienter des demandeurs d'emploi

Tâche IA

- Prédire le délai de retour à l'emploi en 3 classes (0 : rapide <6 mois, 1 : moyen 6-12 mois, 2 : long >12 mois)
- A partir de données multimodales (tabulaire + texte libre)



Impacts

- Direct : aide à l'orientation pour les conseillers
- Indirect : les demandeurs d'emploi

Cadrage métier & problème - Critères de succès

Comment savoir si notre solution est un vrai succès métier, technique et opérationnel ?

Type	Critère	Cible initiale
Métier	Réduire les erreurs critiques (classe 2 : long prédit en 0 : rapide)	< 5 %
Modèle	F1-score macro	≥ 75 %
Modèle	Matrice de confusion	Recall ≥ 85 %
Opérationnel	Temps de réponse API en production	Latence P50 < 250 ms

Cadrage métier & problème - Risques éthiques anticipés

Quels risques éthiques et réglementaires entraine l'utilisation de l'IA dans ce contexte

Variables sensibles
nationalite_hors_ue
code_insee_commune
Age
est allocataire
synthese_entretien

Biais potentiels
Classe déséquilibrée
Sous-représentation de certaines populations
Provenance des données
Corrélation entre colonnes
Biais des conseillers dans la synthèse

Cadrage métier & problème - Réglementaires anticipés

Quels risques éthiques et réglementaires entraine l'utilisation de l'IA dans ce contexte ?

RGPD

- Pseudonymisation
- Droit à l'oubli
- Minimisation des données
- Analyse d'impact

AI Act

- Supervision humaine
- Documentation
- Robustesse
- Gestion des logs
- Suivi des dérives

Droit sectoriel

- Non-discrimination algorithmique
- Information sur l'utilisation de l'IA
- Expliquer la logique de traitement

Responsabilité juridique

- Responsabilité en cas d'erreur?
- Tracer la recommandation et la décision

02

Sources des données

Sources des données

De quelles données disposons-nous pour construire le modèle, d'où proviennent-elles et que représente chaque variable ?

- Fichier CSV fourni dans le cadre de l'examen CISIA : dataset de 2500 lignes et 10 colonnes

Variables	Type	Plage / valeurs	Sensible ?
usager_id	Identifiant (chaîne de caractères)	`ID_0000` … `ID_2499`	Pseudonyme
age	Numérique (entier)	18 – 63 ans	Discrimination
niveau_diplome	Catégoriel (ordinal)	`Sans diplôme`, `Bac`, `Bac+2`, `Bac+5`	❌
anciennete_poste_ans	Numérique (continue)	0,0 – 22,6 ans	❌
code_rome_vise	Catégoriel (nominal)	`D1503`, `G1302`, …	❌
code_insee_commune	Catégoriel (nominal)	`18273`, `55044`, …	Proxy
est_allocataire	Binaire	0 = non, 1 = oui	Précarité
nationalite_hors_ue	Binaire	0 = UE, 1 = hors UE	Discrimination
synthese_entretien	Texte	Phrases courtes	PII ?
classe_retour_emploi	Catégoriel (ordinal)	0 = <6 mois, 1 = 6–12 mois, 2 = >12 mois	

03

Exploration & analyse des données

Exploration & analyse des données (EDA)

Quelle est la qualité des données et comment se répartissent-elles dans le jeu de données ?

```
Valeurs manquantes :
usager_id                0
age                    122
niveau_diplome          84
anciennete_poste_ans     0
code_rome_vise           0
code_insee_commune       0
est_allocataire         44
nationalite_hors_ue      0
synthese_entretien      81
classe_retour_emploi     0
dtype: int64

Lignes en doublon : 0
```

- Aucun doublon de ligne détecté
- Manquants :
  - age : 4,9% de valeurs manquantes
  - niveau_diplome : 3,4% de valeurs manquantes
  - est_allocataire : 1,8% de valeurs manquantes
  - synthese_entretien : 3,2% de valeurs manquantes
- Cohérence :
  - Age légal pour travailler : 16 ans
- Texte de synthèse d'entretien

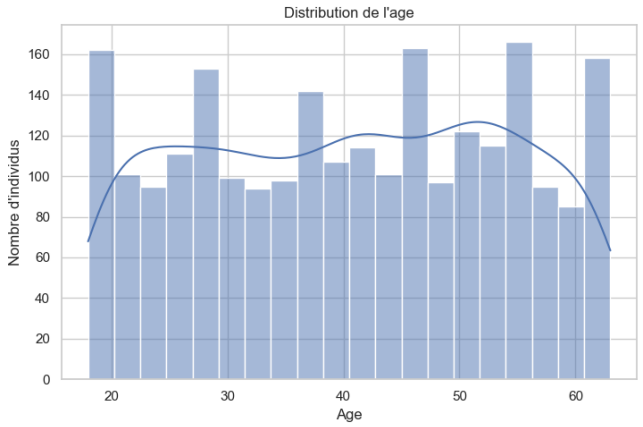
	usager_id	age	niveau_diplome	anciennete_poste_ans	classe_retour_emploi
89	ID_0089	18.0	Bac	7.0	1
94	ID_0094	18.0	Bac	5.2	0
129	ID_0129	18.0	Bac	5.5	0
156	ID_0156	24.0	Bac+2	13.7	0
220	ID_0220	22.0	Bac	8.9	1
302	ID_0302	20.0	Bac	8.1	1
332	ID_0332	23.0	Sans diplôme	8.2	1
358	ID_0358	19.0	Bac+5	5.6	0
380	ID_0380	18.0	Bac+5	3.1	2
390	ID_0390	19.0	Sans diplôme	4.2	1

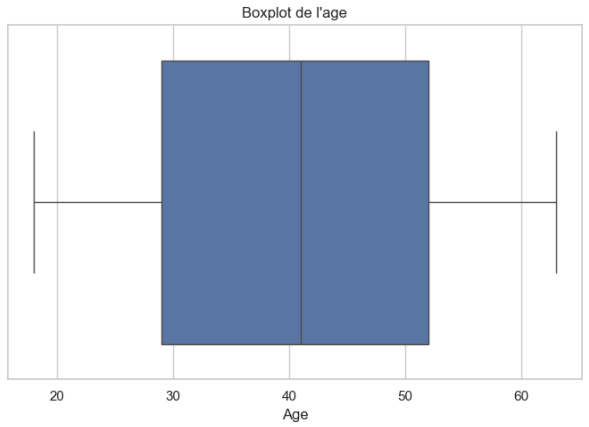
```
['Compétences à réactualiser sur les outils numériques. Motivation correcte.',
 "Cumul de difficultés. Pas de moyen de transport et garde d'enfants complexe.",
 'Problème ponctuel de mobilité géographique. Zone mal desservie.',
 "Projet de reconversion à affiner. Besoin d'une formation complémentaire.",
 'Excellente présentation, compétences techniques à jour. Reprise rapide visée.',
 'Candidat très dynamique, mobilité nationale validée. Projet clair.',
 "Perte de confiance importante. Risque d'exclusion, barrière de la langue.",
 "Freins périphériques majeurs. Situation d'illettrisme numérique constatée.",
 'Profil autonome, recherche active, aucun frein périphérique identifié.',
 nan]
```

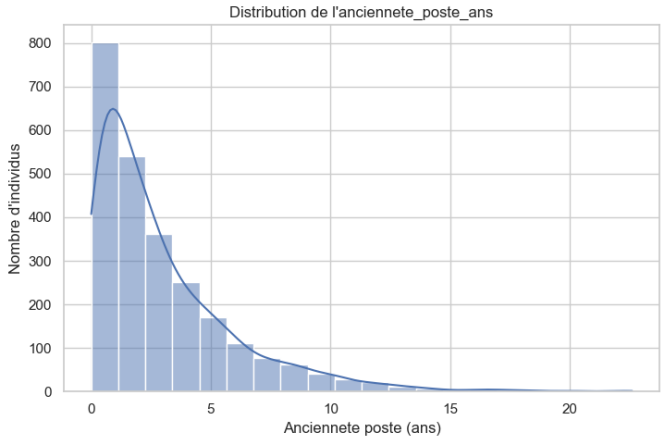
Exploration & analyse des données (EDA)

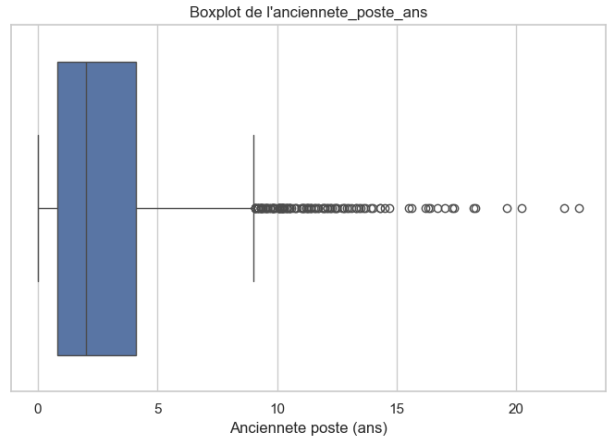
Quelle est la qualité des données et comment se répartissent-elles dans le jeu de données ?

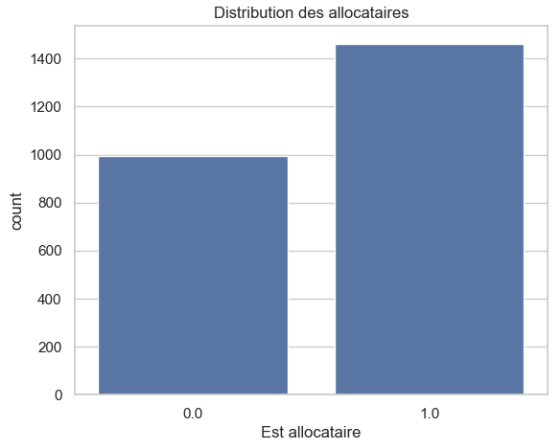
- Distribution des variables

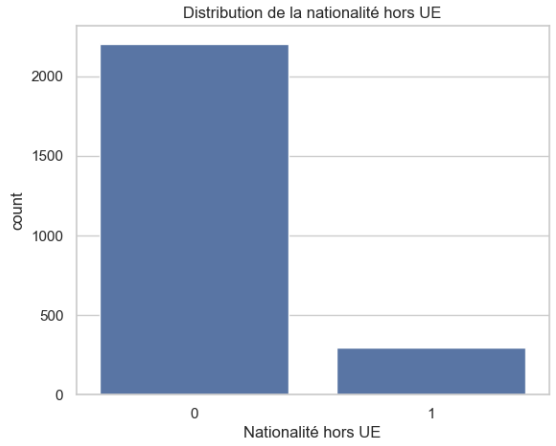


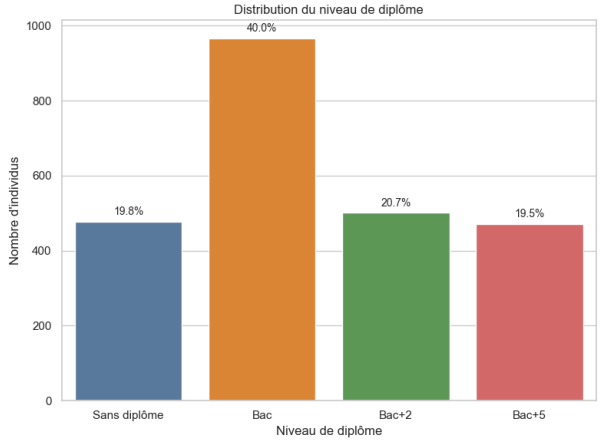


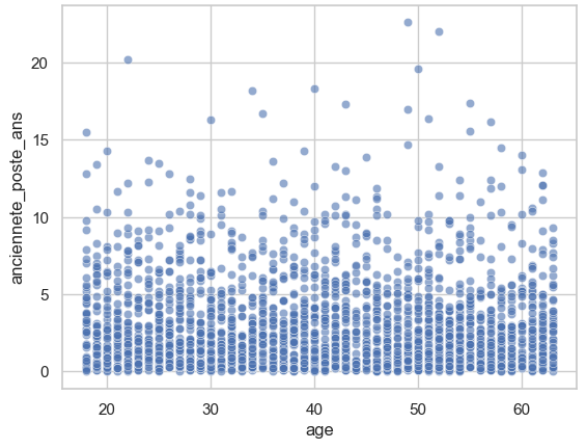








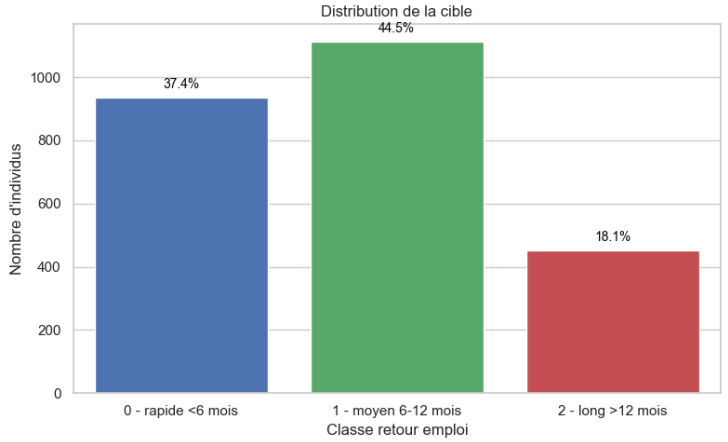




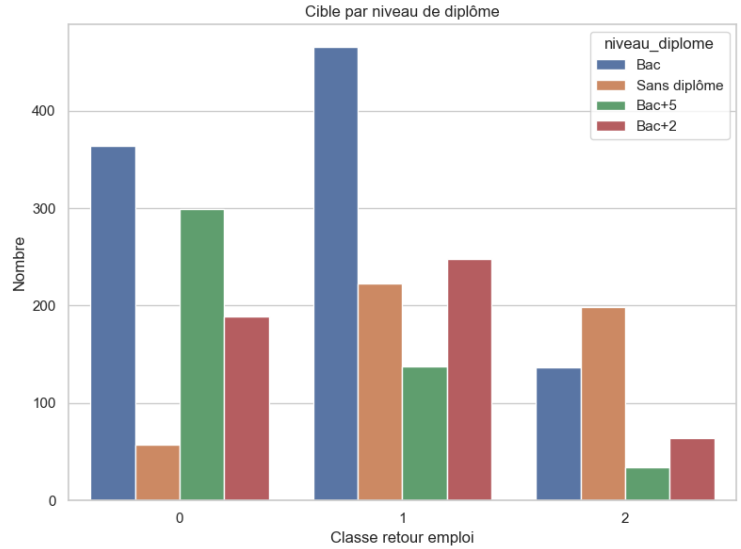
Exploration & analyse des données (EDA)

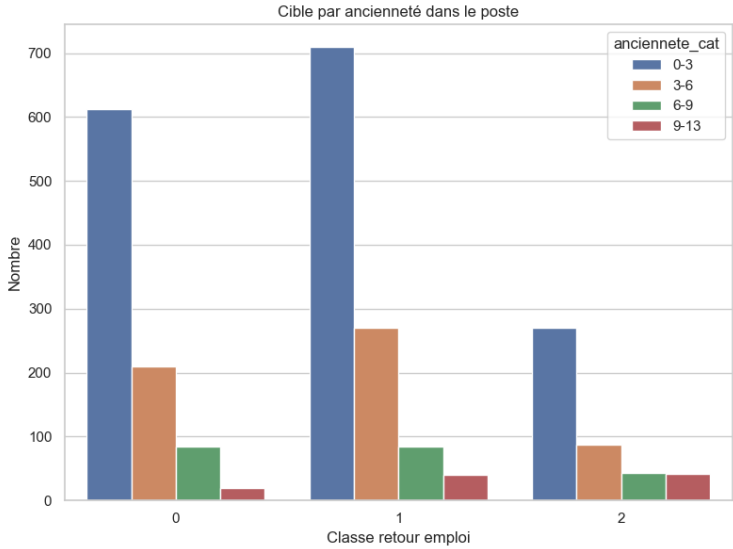
Quelle est la qualité des données et comment se répartissent-elles dans le jeu de données ?

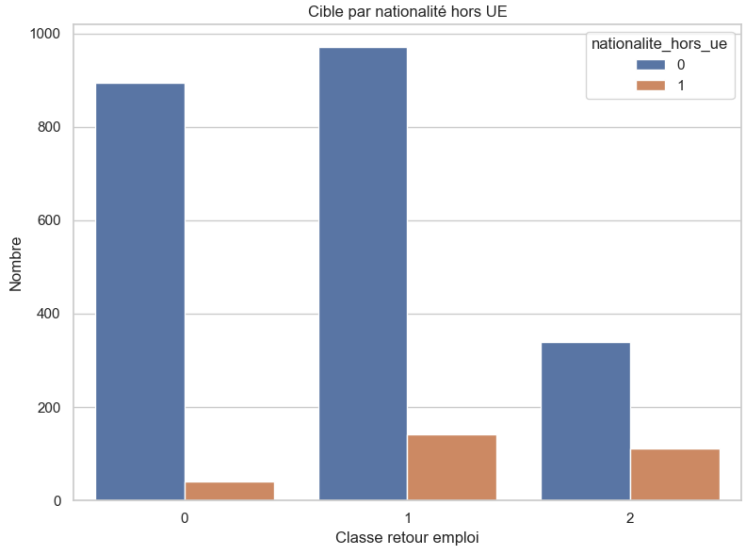
- Variable cible : équilibre & distribution

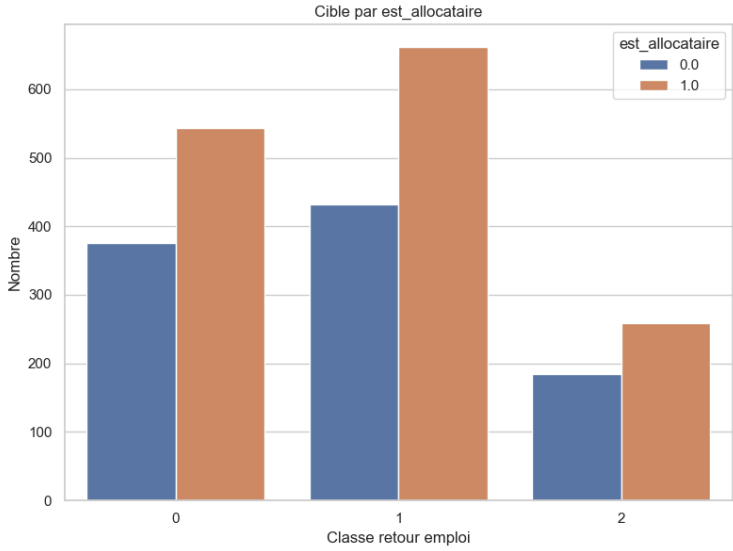


classe_retour_emploi	0	1	2	All
synthese_entretien				
Candidat très dynamique, mobilité nationale validée. Projet clair.	176	61	22	259
Compétences à réactualiser sur les outils numériques. Motivation correcte.	49	265	24	338
Cumul de difficultés. Pas de moyen de transport et garde d'enfants complexe.	57	61	109	227
Excellente présentation, compétences techniques à jour. Reprise rapide visée.	195	56	21	272
Freins périphériques majeurs. Situation d'illettrisme numérique constatée.	52	60	90	202
Non renseigné	32	36	13	81
Perte de confiance importante. Risque d'exclusion, barrière de la langue.	63	51	98	212
Problème ponctuel de mobilité géographique. Zone mal desservie.	56	249	29	334
Profil autonome, recherche active, aucun frein périphérique identifié.	209	66	25	300
Projet de reconversion à affiner. Besoin d'une formation complémentaire.	47	207	21	275
All	936	1112	452	2500





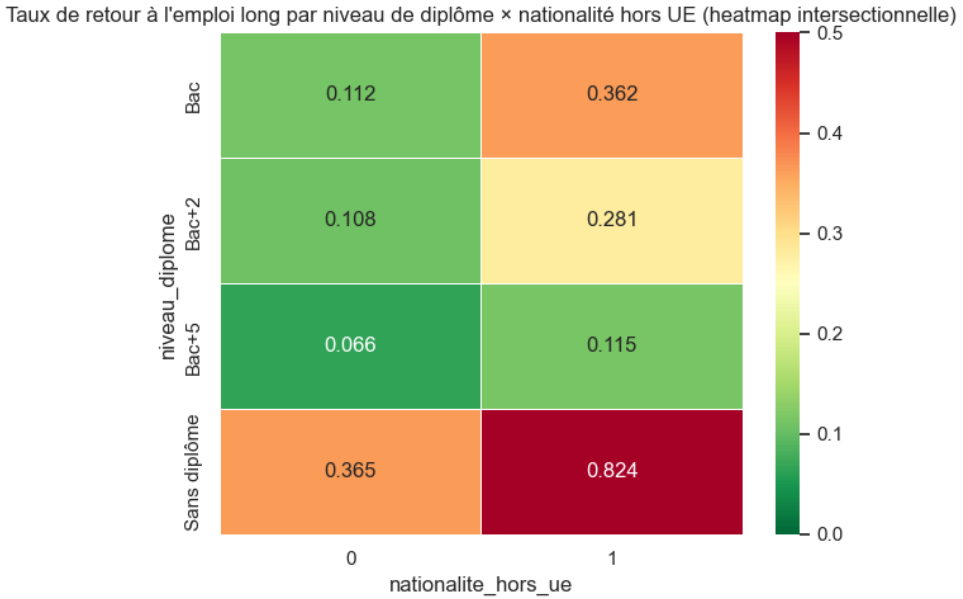




Exploration & analyse des données (EDA)

Quelle est la qualité des données et comment se répartissent-elles dans le jeu de données ?

- Relations entre variables



- Disparate Impact

```
age: DI = 0.134  (⚠️ SIGNAL), groupe défavorisé : 60.0 (0.081), groupe favorisé : 26.0 (0.604)
nationalite_hors_ue: DI = 0.342  (⚠️ SIGNAL), groupe défavorisé : 1 (0.139), groupe favorisé : 0 (0.406)
est_allocataire: DI = 0.980  (✅ OK), groupe défavorisé : 1.0 (0.371), groupe favorisé : 0.0 (0.379)
niveau_diplome: DI = 0.188  (⚠️ SIGNAL), groupe défavorisé : Sans diplôme (0.119), groupe favorisé : Bac+5 (0.635)

(0.187843718951596,
 niveau_diplome
 Bac             0.376812
 Bac+2           0.377246
 Bac+5           0.634820
 Sans diplôme    0.119247
 Name: classe_retour_emploi, dtype: float64)
```

Exploration & analyse des données (EDA)

Quelle est la qualité des données et comment se répartissent-elles dans le jeu de données ?

- Conclusion et révision des critères de succès

Type	Critère	Cible initiale (client)	Cible révisée après EDA	Justification de la révision
Métier	Réduire les erreurs critiques (classe 2 prédit 0)	<5%	<5%	On va essayer de minimiser l'erreur critque qui a le plus fort coût humain et financier. Cependant la classe 2 est minoritaire et il y a peu de données, cela sera dur à prédire donc on reste sur la même cible.
Modèle	F1-score macro	F1-score macro ≥ 0.75	F1-score macro ≥ 0.70	La classe 2 est minoritaire et il y a peu de données, une revue à la baisse est nécessaire.
Modèle	Matrice de confusion	Recall ≥ 85% pour classe 2	Recall ≥ 70% pour classe 2	La classe 2 est minoritaire et il y a peu de données, une revue à la baisse est nécessaire.
Opérationnel	Temps de réponse API en production	Latence : P50 < 250 ms	on ne modifie pas	ça reste réaliste
Robustesse	Traiter les manquants et les incohérences	non défini précédemment	100%	Il faut que les manquants soient traités à 100%
Equité	Limiter les disparités entre sous-groupes sensibles	non défini précédemment	écart de recall classe 2 entre groupes ≤ 10	L'EDA montre des DI < 0,8 et donc un risque de discrimination statistique

Préparation des données et scénarios de jeux de données

Comment préparer les données de manière fiable et reproductible

- Prétraitement :
  - Remplacement du code INSEE par le département
  - Incohérences age <-> ancienneté : on positionne ancienneté à `NaN`
  - Exclue les identifiants `usager_id`
- Split des données :

Jeu	Lignes	Part	Classe 0 / 1 / 2
Train	2 000	80 %	749 / 889 / 362
Test	500	20 %	187 / 223 / 90
Protocole	Stratifié, random_state fixé	-	Répartition concervé

classe_retour_emploi	Avant split	Train	Test
1	0.445	0.444	0.446
0	0.374	0.374	0.374
2	0.181	0.181	0.180

- **Pipelines** :

Type de variable	Traitements
Numérique	Valeurs manquantes = médiane + mise à l'échelle
Catégoriel (ordinal)	Manquantes = modalité la plus fréquente + encode selon l'ordre
Catégoriel (nominal)	Manquantes = modalité la plus fréquente + encodage one-hot + ignore les modalités inconnues
Texte	Manquantes = vide + Transforme 2D en 1D + Vectorisation TF-IDF

04

Préparation des données et scénarios de jeux de données

Préparation des données et scénarios de jeux de données

Comment préparer les données de manière fiable et reproductible

- Scénarios de jeux de données

Scénario	Variables conservées	Justifications
Scénario 1 — Approche multimodale complète	Toutes les variables (tabulaires + texte vectorisé)	Baseline complète de référence
Scénario 2 — Sans variables sensibles (Approche Éthique)	Variables non sensibles uniquement (avec justification CNIL/RGPD)	Mesurer l'impact du retrait des variables sensibles sur les performances / les biais
Scénario 3 — Diagnostic par le texte seul (NLP pure)	`synthese_entretien` uniquement	Tester la robustesse du modèle de langage face à des verbatims contenant du bruit stochastique
Scénario 4 — Données contextuelles pures (Tabulaire seul)	Variables tabulaires uniquement (sans texte)	Mesurer l'apport du texte en comparaison du tabulaire seul
Scénario 1 — Approche hybride (ajouté dans un second temps)	Toutes les variables à l'exception de `nationalite_hors_ue`	Depuis le scénario le plus performant, tout en limitant les risques de discrimination

05

Modélisation & entrainement

Modélisation & entrainement - Familles candidates & Modèles candidats

Quelles familles de modèles peut-on envisager pour cette classification, et quels modèles retenir ?

- Familles candidates : choix raisonné

Famille	Décision
ML classique (sklearn, XGBoost)	Retenue : baseline principale et candidats prioritaires pour comparer performance, robustesse et coût
Deep Learning (Keras / PyTorch)	**Écartée à ce stade** : coût et complexité disproportionnés pour 2 500 lignes
SLM local (Ollama, modèles ≤ 7B)	**Écartée** : utile pour de la génération, pas pour de classification structurée
LLM API + RAG	**Écartée** : Non adapté au besoin principal
Architecture agentique (multi-LLM, tools)	**Écartée** : complexité opérationnelle importante et valeur ajoutée limitée pour ce cas d'usage

- Modèles candidats

Modèle	Justification	Coût : entrainement / inférence	Explicabilité
LogisticRegression	Baseline robuste, rapide et stable	faible / faible	élevée
XGBoost Classifier	Très bon compromis attendu sur tabulaire	moyen à élevé / moyen	moyenne
LightGBM Classifier	Adaptée aux features encodées en grande dimension	moyen / faible à moyen	moyenne
RandomForestClassifier	Bon point de comparaison face aux méthodes de boosting	moyen / faible	moyenne

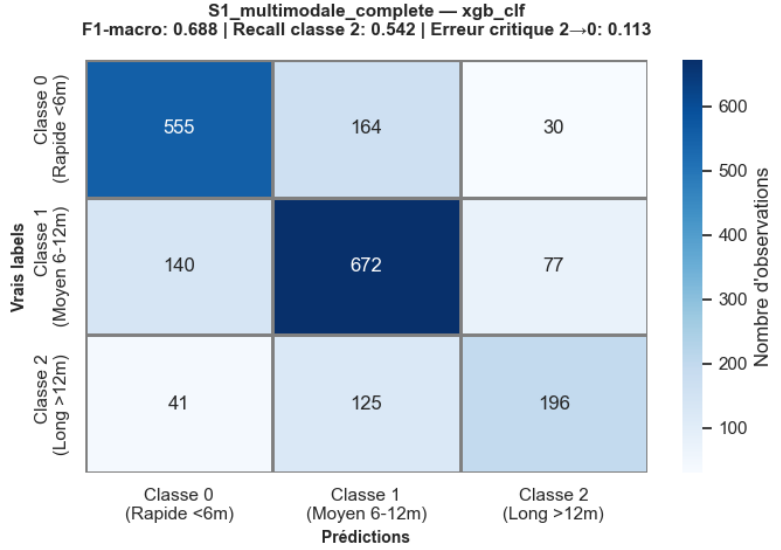
Modélisation & entrainement - Métriques retenues & justification

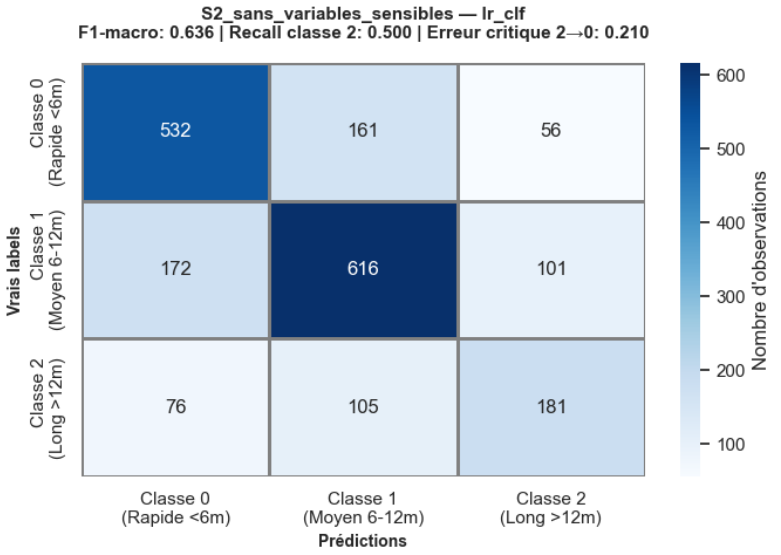
Quels indicateurs choisir pour évaluer le modèle et pourquoi sont-ils adaptés à notre objectif métier ?

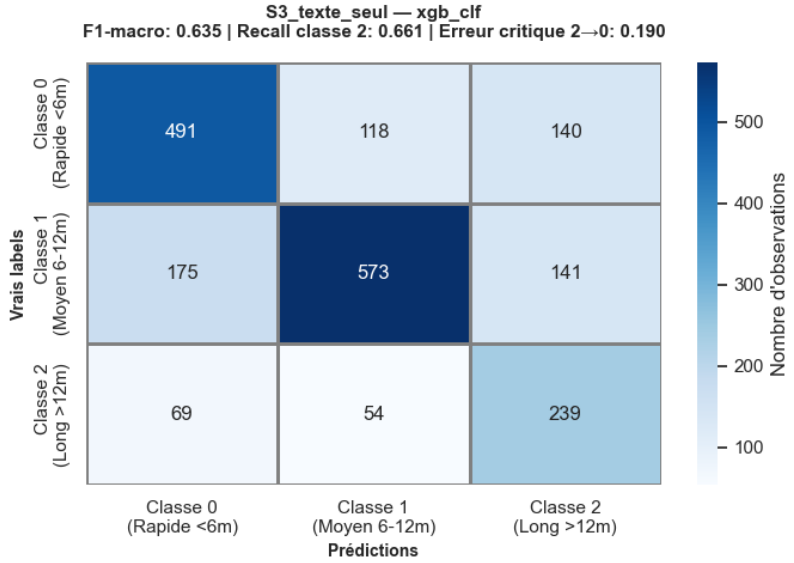
Métrique	Ce qu'elle mesure	Pourquoi elle est retenue ici
f1_macro	Moyenne des F1 de chaque classe (precision × recall équilibrés), pondération égale entre classes	**Mesure principale** : pénalise les modèles qui ignorent une classe. Insensible au déséquilibre car ne dépend pas des effectifs. Permet de comparer tous les candidats sur le même pied.
écart-type (f1_macro)	Dispersion du f1_macro entre les 5 folds de la validation croisée	Mesure la **stabilité** du modèle : un f1_macro élevé mais avec un écart-type fort indique un modèle instable, sensible à la composition du fold. Un modèle stable (faible écart-type) est plus fiable en production.
recall_classe_2	Parmi tous les vrais demandeurs d'emploi de classe 2 (risque de longue durée), quelle fraction le modèle détecte-t-il ?	Classe 2 = profils les plus vulnérables. Un recall faible signifie qu'on rate des personnes qui auraient besoin d'un accompagnement renforcé → coût social élevé. **Sensibilité prioritaire.**
precision_classe_2	Parmi les prédictions classe 2, quelle fraction est vraiment classe 2 ?	Évite les fausses alertes : déclencher un accompagnement renforcé inutilement est coûteux en ressources. Complète le recall pour ne pas sur-classifier.
f1_classe_2	Moyenne harmonique de recall et precision sur la seule classe 2	Synthèse équilibrée du compromis détection / faux positifs sur la classe la plus sensible. Métrique de décision complémentaire au f1_macro.
erreur_critique_2_vers_0	Taux de demandeurs d'emploi réellement classe 2 prédits comme classe 0 (pas de difficulté)	**Erreur la plus grave** du système : orienter vers "retour rapide" quelqu'un qui a besoin d'un soutien long. Cette métrique custom quantifie précisément ce risque. À minimiser absolument.
log_loss	Pénalise les probabilités mal calibrées (confiance élevée sur une mauvaise prédiction)	Mesure la qualité de calibration : un modèle qui dit "95 % classe 0" quand classe 2 est plus dangereux qu'un modèle incertain. Utile pour comparer la fiabilité des sorties de probabilité entre candidats. Le plus proche de 0 est le mieux

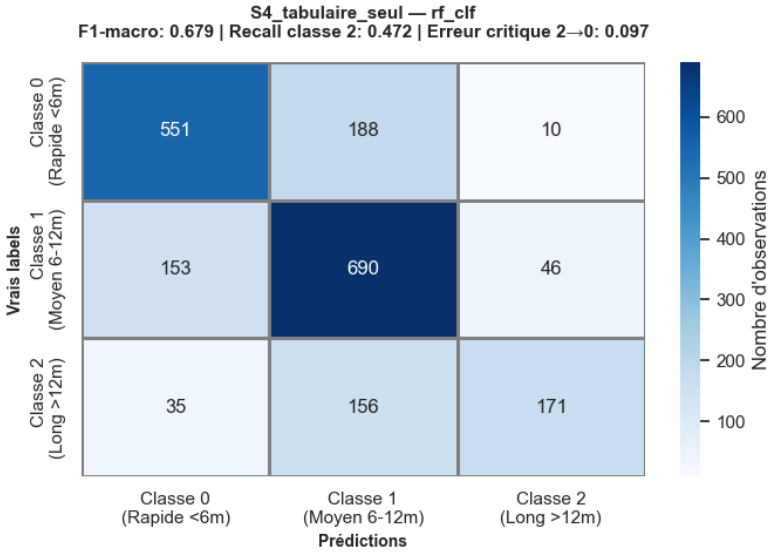
Modélisation & entrainement – Validation croisée

Quel modèle obtient les meilleurs résultats en validation croisée ?









Optimisation des hyperparamètres - LogisticRegression

Comment optimiser les hyperparamètres pour améliorer les performances des modèles ?

- Hyperparamètres explorés : solver, C, class_weight, max_iter

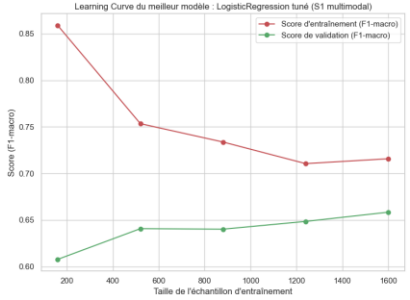
10 meilleurs réglages :

	scenario	solver	C	class_weight	max_iter	f1_macro	recall_c2	critical_2_to_0
4	S1_multimodale_complete	lbfgs	0.5	None	2000	0.672	0.550	0.163
5	S1_multimodale_complete	lbfgs	0.5	None	3000	0.672	0.550	0.163
12	S1_multimodale_complete	saga	0.5	None	2000	0.672	0.550	0.163
13	S1_multimodale_complete	saga	0.5	None	3000	0.672	0.550	0.163
14	S1_multimodale_complete	saga	0.5	balanced	2000	0.668	0.677	0.152
15	S1_multimodale_complete	saga	0.5	balanced	3000	0.668	0.677	0.152
6	S1_multimodale_complete	lbfgs	0.5	balanced	2000	0.667	0.674	0.152
7	S1_multimodale_complete	lbfgs	0.5	balanced	3000	0.667	0.674	0.152
8	S1_multimodale_complete	saga	1.0	None	2000	0.663	0.533	0.169
9	S1_multimodale_complete	saga	1.0	None	3000	0.663	0.533	0.169

5 moins bons réglages :

	scenario	solver	C	class_weight	max_iter	f1_macro	recall_c2	critical_2_to_0
63	S4_tabulaire_seul	saga	0.5	balanced	3000	0.528	0.591	0.149
58	S4_tabulaire_seul	saga	1.0	balanced	2000	0.521	0.569	0.157
59	S4_tabulaire_seul	saga	1.0	balanced	3000	0.521	0.569	0.157
50	S4_tabulaire_seul	lbfgs	1.0	balanced	2000	0.518	0.561	0.157
51	S4_tabulaire_seul	lbfgs	1.0	balanced	3000	0.518	0.561	0.157

- Courbe d'apprentissage :



- Paramètres retenus :

solver="lbfgs",

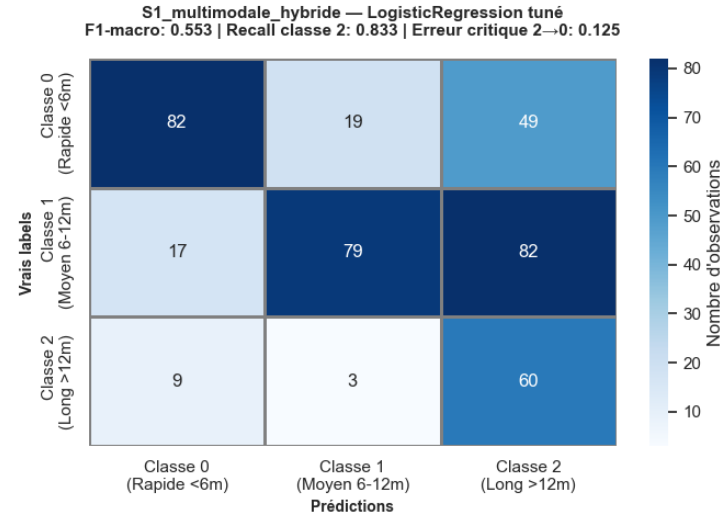
C=0.1,

max_iter=1000

random_state=RANDOM_STATE

n_jobs=-1,

class_weights_lr = {0: 1.0, 1: 1.0, 2: 3.0}



- Filet de sécurité et revue humaine :

Seuil	Dossiers en revue	Erreur critique	Erreur critique en revue
0,2	202	9	7
0,25	200	9	7
0,30	199	9	7
0,35	199	9	7
0,4	199	9	7

Optimisation des hyperparamètres - XGBClassifier

Comment optimiser les hyperparamètres pour améliorer les performances des modèles ?

- Hyperparamètres explorés : n_estimators, learning_rate, max_depth, colsample_bytree

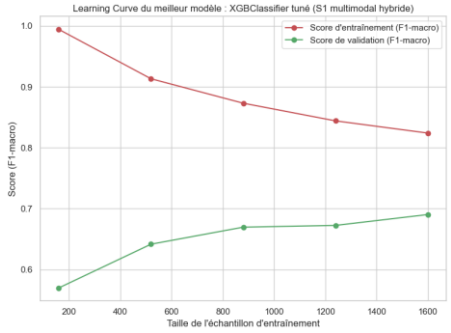
10 meilleurs réglages :

	scenario	n_estimators	learning_rate	max_depth	colsample_bytree	f1_macro	recall_c2	critical_2_to_0
2	S1_multimodale_complete	50	NaN	4.0	0.5	0.706	0.575	0.132
15	S1_multimodale_complete	300	0.05	4.0	0.7	0.706	0.572	0.124
12	S1_multimodale_complete	300	0.05	NaN	0.5	0.705	0.555	0.130
0	S1_multimodale_complete	50	NaN	NaN	0.5	0.704	0.569	0.127
1	S1_multimodale_complete	50	NaN	NaN	0.7	0.704	0.564	0.124
14	S1_multimodale_complete	300	0.05	4.0	0.5	0.703	0.569	0.130
13	S1_multimodale_complete	300	0.05	NaN	0.7	0.698	0.550	0.130
11	S1_multimodale_complete	300	NaN	4.0	0.7	0.695	0.558	0.135
3	S1_multimodale_complete	50	NaN	4.0	0.7	0.695	0.558	0.133
10	S1_multimodale_complete	300	NaN	4.0	0.5	0.693	0.553	0.124

5 moins bons réglages :

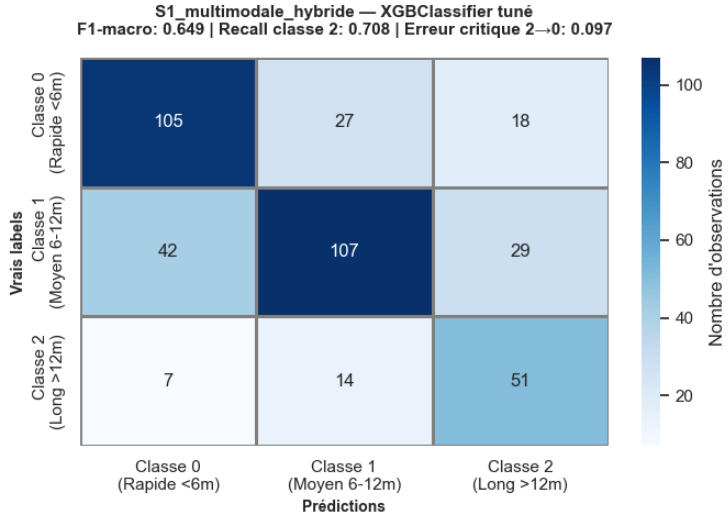
	scenario	n_estimators	learning_rate	max_depth	colsample_bytree	f1_macro	recall_c2	critical_2_to_0
57	S4_tabulaire_seul	300	NaN	NaN	0.7	0.617	0.464	0.091
26	S2_sans_variables_sensibles	300	NaN	4.0	0.5	0.602	0.453	0.188
27	S2_sans_variables_sensibles	300	NaN	4.0	0.7	0.599	0.459	0.185
25	S2_sans_variables_sensibles	300	NaN	NaN	0.7	0.590	0.448	0.182
24	S2_sans_variables_sensibles	300	NaN	NaN	0.5	0.585	0.439	0.177

- Courbe d'apprentissage :



- Paramètres retenus :

objective="multi:softprob"
num_class=3
n_estimators=500
learning_rate=0.03
max_depth=5
colsample_bytree=0.7
random_state=RANDOM_STATE
n_jobs=-1,
class_weights_lr = {0: 1.0, 1: 1.0, 2: 3.0}



- Filet de sécurité et revue humaine :

Seuil	Dossiers en revue	Erreur critique	Erreur critique en revue
0,2	127	7	3
0,25	124	7	3
0,30	124	7	3
0,35	124	7	3
0,4	124	7	3

Optimisation des hyperparamètres - LGBMClassifier

Comment optimiser les hyperparamètres pour améliorer les performances des modèles ?

- Hyperparamètres explorés : n_estimators, learning_rate, num_leaves, min_child_samples, colsample_bytree

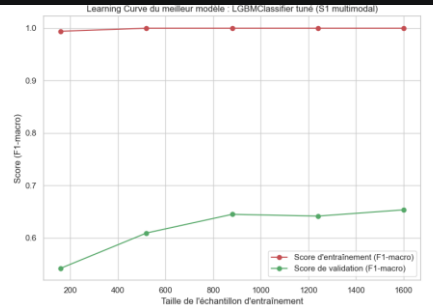
10 meilleurs réglages :

	scenario	n_estimators	learning_rate	num_leaves	min_child_samples	colsample_bytree	f1_macro	recall_c2	critical_2_to_0
21	S1_multimodale_complete	400	0.02	24	10	0.7	0.715	0.600	0.108
17	S1_multimodale_complete	400	0.02	27	10	0.7	0.710	0.586	0.113
20	S1_multimodale_complete	400	0.02	24	10	0.5	0.710	0.583	0.108
13	S1_multimodale_complete	50	0.05	24	10	0.7	0.704	0.569	0.138
16	S1_multimodale_complete	400	0.02	27	10	0.5	0.704	0.580	0.113
8	S1_multimodale_complete	50	0.05	27	10	0.5	0.699	0.564	0.146
12	S1_multimodale_complete	50	0.05	24	10	0.5	0.698	0.564	0.144
9	S1_multimodale_complete	50	0.05	27	10	0.7	0.697	0.555	0.133
28	S1_multimodale_complete	400	0.05	24	10	0.5	0.696	0.575	0.108
25	S1_multimodale_complete	400	0.05	27	10	0.7	0.695	0.575	0.116

5 moins bons réglages :

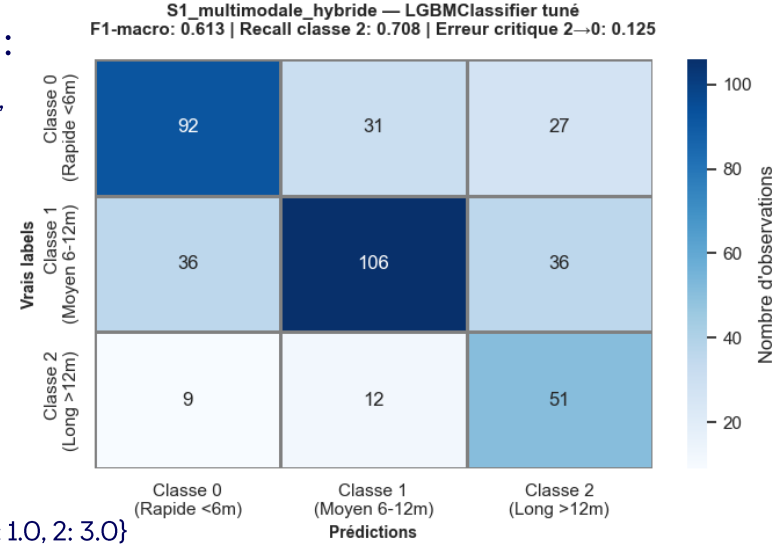
	scenario	n_estimators	learning_rate	num_leaves	min_child_samples	colsample_bytree	f1_macro	recall_c2	critical_2_to_0
100	S4_tabulaire_seul	50	0.02	24	10	0.5	0.572	0.166	0.066
103	S4_tabulaire_seul	50	0.02	24	40	0.7	0.555	0.268	0.119
99	S4_tabulaire_seul	50	0.02	27	40	0.7	0.552	0.263	0.119
102	S4_tabulaire_seul	50	0.02	24	40	0.5	0.480	0.119	0.102
98	S4_tabulaire_seul	50	0.02	27	40	0.5	0.474	0.113	0.102

- Courbe d'apprentissage :



- Paramètres retenus :

objective="multiclass", num_class=3, n_estimators=700, learning_rate=0.025, num_leaves=24, max_depth=8, min_child_samples=35, subsample=0.8, colsample_bytree=0.6, reg_alpha=0.2, reg_lambda=1.5, random_state=RANDOM_STATE, n_jobs=-1, class_weights_lr = {0: 1.0, 1: 1.0, 2: 3.0}



- Filet de sécurité et revue humaine :

Seuil	Dossiers en revue	Erreur critique	Erreur critique en revue
0,2	110	9	4
0,25	106	9	3
0,30	105	9	3
0,35	105	9	3
0,4	105	9	3

Optimisation des hyperparamètres - RandomForestClassifier

Comment optimiser les hyperparamètres pour améliorer les performances des modèles ?

- Hyperparamètres explorés : n_estimators, max_depth, min_samples_leaf, max_features, class_weight

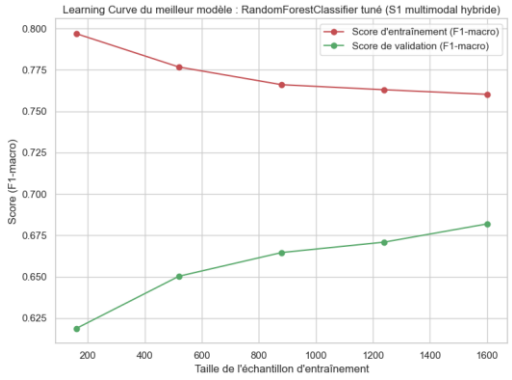
10 meilleurs réglages :

	scenario	n_estimators	max_depth	min_samples_leaf	max_features	class_weight	f1_macro	recall_c2	critical_2_to_0
43	S1_multimodale_complete	500	18	2	0.35	balanced_subsample	0.688	0.644	0.146
19	S1_multimodale_complete	500	18	2	0.35	balanced	0.688	0.647	0.141
22	S1_multimodale_complete	500	18	4	0.35	balanced	0.686	0.696	0.135
31	S1_multimodale_complete	50	18	2	0.35	balanced_subsample	0.685	0.633	0.152
46	S1_multimodale_complete	500	18	4	0.35	balanced_subsample	0.684	0.688	0.144
7	S1_multimodale_complete	50	18	2	0.35	balanced	0.683	0.644	0.141
10	S1_multimodale_complete	50	18	4	0.35	balanced	0.683	0.674	0.138
28	S1_multimodale_complete	50	5	4	0.35	balanced_subsample	0.682	0.688	0.144
34	S1_multimodale_complete	50	18	4	0.35	balanced_subsample	0.682	0.674	0.138
1	S1_multimodale_complete	50	5	2	0.35	balanced	0.681	0.691	0.144

5 moins bons réglages :

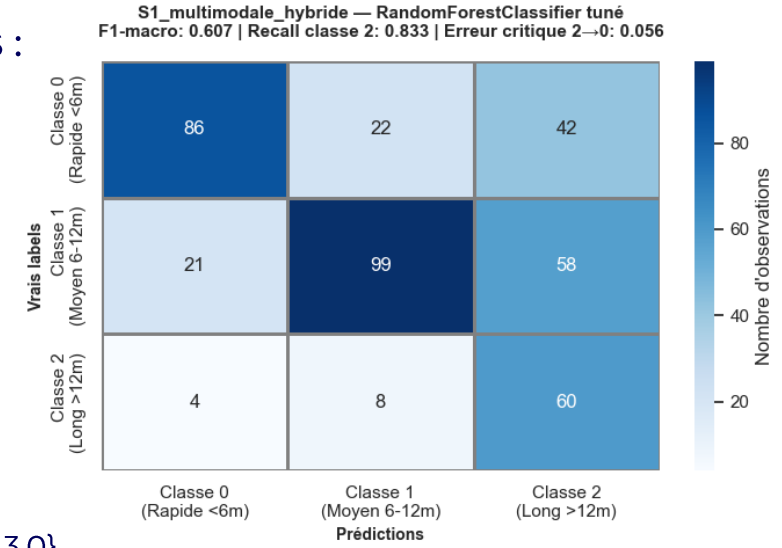
	scenario	n_estimators	max_depth	min_samples_leaf	max_features	class_weight	f1_macro	recall_c2	critical_2_to_0
170	S4_tabulaire_seul	50	5	2	log2	balanced_subsample	0.514	0.693	0.185
146	S4_tabulaire_seul	50	5	2	log2	balanced	0.510	0.677	0.207
185	S4_tabulaire_seul	500	5	4	log2	balanced_subsample	0.510	0.688	0.191
149	S4_tabulaire_seul	50	5	4	log2	balanced	0.506	0.674	0.196
173	S4_tabulaire_seul	50	5	4	log2	balanced_subsample	0.504	0.680	0.204

- Courbe d'apprentissage :



- Paramètres retenus :

n_estimators=500,
max_depth=12,
min_samples_split=5,
min_samples_leaf=4,
max_features="sqrt",
max_samples=0.8,
bootstrap=True,
random_state=RANDOM_STATE,
n_jobs=-1,
class_weights_lr = {0: 1.0, 1: 1.0, 2: 3.0}



- Filet de sécurité et revue humaine :

Seuil	Dossiers en revue	Erreur critique	Erreur critique en revue
0,2	297	4	4
0,25	297	4	4
0,30	297	4	4
0,35	297	4	4
0,4	297	4	4

Optimisation des hyperparamètres – Comparaison des finalistes

Comment optimiser les hyperparamètres pour améliorer les performances des modèles ?

- Hypothèse de coûts :

Type d'hypothèse	Coût proposé
Erreur d'orientation modérée « 0 → 1 » ou « 1 → 0 »	1 000 €
Intensité d'accompagnement mal évaluée « 1 → 2 » ou « 2 → 1 »	5 000 €
Mobilisation excessive de ressources « 0 → 1 »	8 000 €
Erreur critique « 0 → 1 »	15 000 €
Revue manuelle d'un dossier	20 €

- Résultats :

Scénario	Modèle	F1 macro	Rappel C2	Erreur critique	Coût après filet
S1 hybride	XGBoost	**0,692 (± 0,033)**	0,703	0,110	**234 270 €**
S1 hybride	LightGBM	0,627 (± 0,019)	0,703	0,124	391 100 €
S1 hybride	RF	0,597 (± 0,025)	0,807	**0,059**	371 970 €
S1 hybride	Reg Log	0,561 (± 0,017)	**0,841**	0,062	448 020 €
S2	Reg Log	0,634 (± 0,029)	0,483	0,224	265 370 €
S3	RF	0,637 (± 0,028)	0,666	0,176	300 190 €

Modélisation & entrainement – Evaluation sur le test

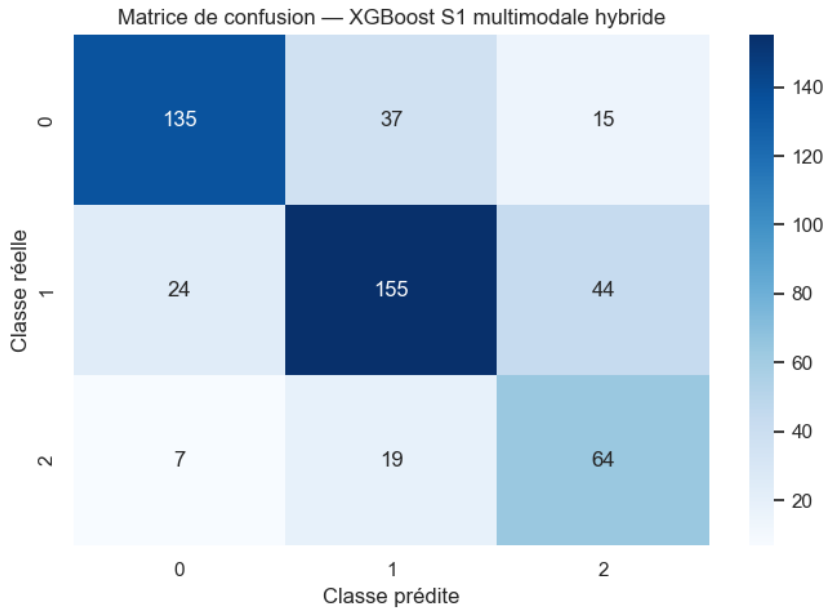
Le couple XGBoost & S1 hybride conserve-t-il de bonnes performances sur des données jamais vues ?

Modèle retenu	Scénario	Erreur critique	F1-macro	Recall C2	Hyperparamètres principaux
XGBClassifier pondéré	S1 multimodale hybride	0,110	0,692 ± 0,033	0,703	n_estimators=500, learning_rate=0.03, max_depth=5, colsample_bytree=0.7, poids `{0:1, 1:1, 2:3}`

- Coût d'inférence : 0,50 € par heure de CPU

- Résultat sur le test final :

F1 macro	Recall C2	Précision C2	F1 C2	Erreur critique	Latence p95	Coût estimé
0,693	0,711	0,520	0,601	0,078	10,167 ms	0,007852 €



Comparaison avec la baseline DummyClassifier

Critère	DummyClassifier	Modèle retenu
F1 macro	0,206	0,693
Recall classe 2	0,000	0,711
Erreur critique	0,000	0,078

- Limites :
  - Données limitées
  - textes entretien très redondants

06

Analyse des scénarios & arbitrage

Analyse des scénarios & arbitrage

Quel scénario de modélisation recommander au client ?

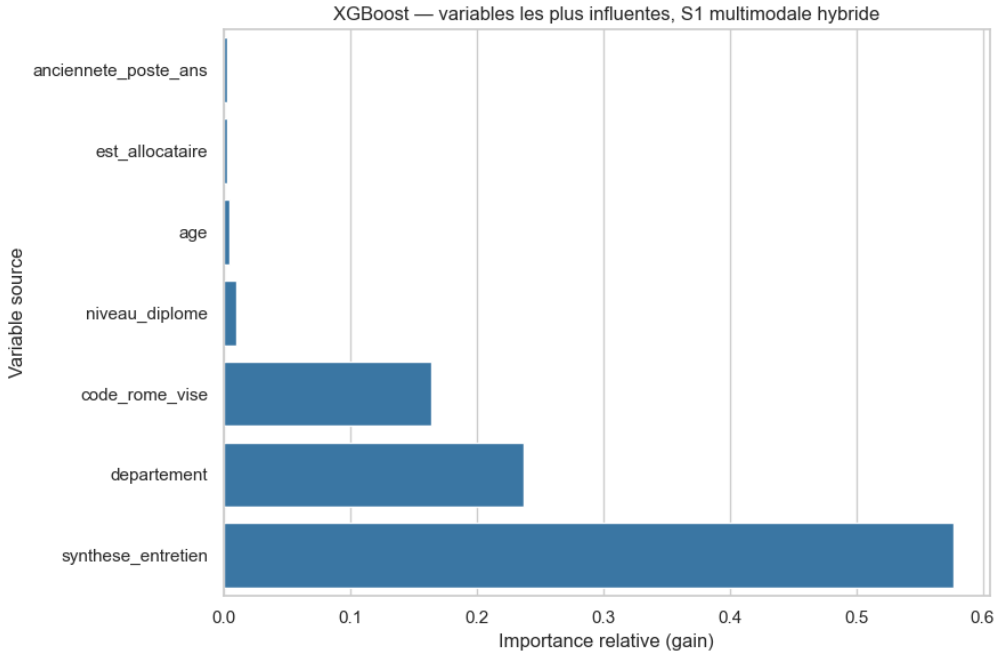
Scénario	Modèle	Pondéré	Statut sans `nationalite_hors_ue`	F1 macro CV	Recall cl.2 CV	Erreur critique 2→0 CV	F1 pondéré X_val	Revue X_val	Erreurs 2→0 automatiques	Coût après abstention X_val (k€)
S1 multimodale complète	XGBoost	Oui	Non	0.697 ± 0.027	0.697	0.110	0.705	132 (33.0 %)	3	202.320
S1 multimodale complète	LightGBM	Oui	Non	0.654 ± 0.024	0.724	0.121	0.660	109 (27.3 %)	5	350.090
S1 multimodale complète	Random Forest	Oui	Non	0.619 ± 0.023	0.817	0.048	0.628	293 (73.2 %)	0	371.930
S1 multimodale complète	Régression logistique	Oui	Non	0.582 ± 0.028	0.852	0.069	0.578	194 (48.5 %)	1	444.940
S1 multimodale hybride	**XGBoost**	Oui	**À confirmer**	**0.692 ± 0.033**	**0.703**	**0.110**	**0.659**	**127 (31.8 %)**	**4**	**234.270**
S1 multimodale hybride	LightGBM	Oui	À confirmer	0.627 ± 0.019	0.703	0.124	0.628	110 (27.5 %)	5	391.100
S1 multimodale hybride	Random Forest	Oui	À confirmer	0.597 ± 0.025	0.807	0.059	0.627	297 (74.2 %)	0	371.970
S1 multimodale hybride	Régression logistique	Oui	À confirmer	0.561 ± 0.017	0.841	0.062	0.573	202 (50.5 %)	2	448.020
S2 sans variables sensibles	Régression logistique	Non	À confirmer	0.634 ± 0.029	0.483	0.224	0.653	137 (34.2 %)	8	265.370
S3 texte seul	Random Forest	Non	À confirmer	0.637 ± 0.028	0.666	0.176	0.636	119 (29.8 %)	13	300.190
S4 tabulaire seul	Random Forest	Non	Non	0.663 ± 0.027	0.424	0.090	0.700	170 (42.5 %)	2	169.700

07

Interprétation client

Interprétation client – Poids des variables & filet de sécurité

Comment interpréter le fonctionnement du modèle et ses limites pour la communication au client ?



Levier	Question à trancher	Exemple concret
Automatisation	Quelle décision le modèle peut-il prendre seul ?	Aucune décision d'orientation : il fournit une classe et des probabilités, que le conseiller peut contredire avant de valider la décision finale.
Rejection threshold	À quel niveau de confiance je préfère m'abstenir plutôt que prédire ?	Orienter en revue si la confiance maximale est `< 0,65`, si l'écart entre les deux meilleures probabilités est `< 0,15`, ou si la classe prédite est 0 avec `P(classe 2) > 0,20`. La classe n'est pas modifiée automatiquement.
Abstention contrôlée	Que renvoie l'API quand le modèle s'abstient ?	Contrat proposé, non encore validé dans l'API : réponse HTTP 200 avec statut `REVUE_HUMAINE`, probabilités et motif de revue. Ne pas traiter cette réponse comme une orientation automatique.
Escalade humaine (HITL)	Qui prend la main, sous quel délai, avec quelle interface ?	Le dossier signalé est présenté au conseiller dans une file de revue, il examine les informations, confirme ou corrige la recommandation et trace sa décision. Interface, responsable et délai de traitement restent à définir avec l'agence.
Capacité de revue	Combien de dossiers peuvent être examinés sans saturer les conseillers ?	Plafond opérationnel supposé de **35 % des dossiers**, à valider avec l'agence. Sur `X_val`, la règle oriente **127/400 dossiers (31,8 %)** en revue : elle reste sous ce plafond, sans marge importante.
Efficacité du filet	Combien d'erreurs critiques échappent à la revue ?	Sur `X_val`, parmi **7 erreurs** `2→0`, **3** sont orientées en revue et **4 restent automatiques**. Une erreur revue n'est pas automatiquement corrigée : le filet n'élimine pas le risque le plus grave.
Métrique d'alerte	Comment détecter une dégradation du modèle ou du filet ?	Suivre le taux de revue, le rappel de la classe 2, les erreurs `2→0` restant automatiques et les écarts entre groupes, réévaluer les seuils ou le modèle en tenant compte de la capacité humaine.

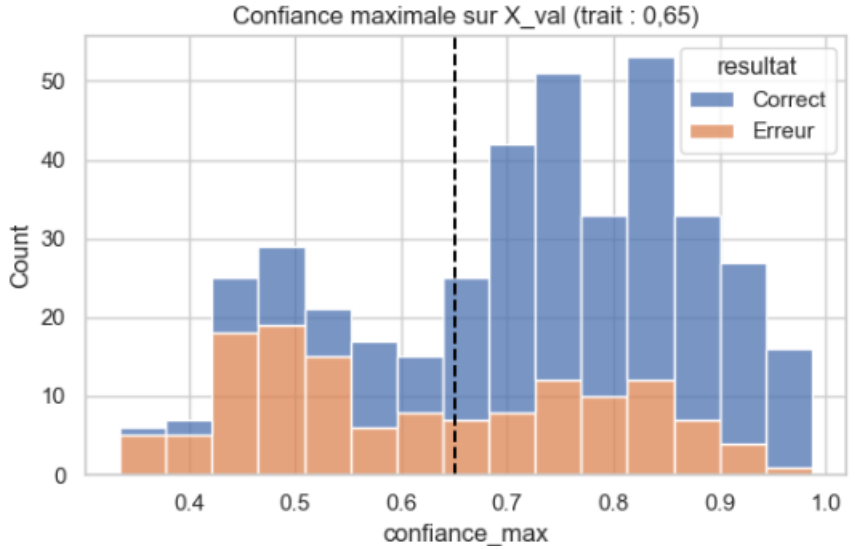
Interprétation client – impacte du filet de sécurité

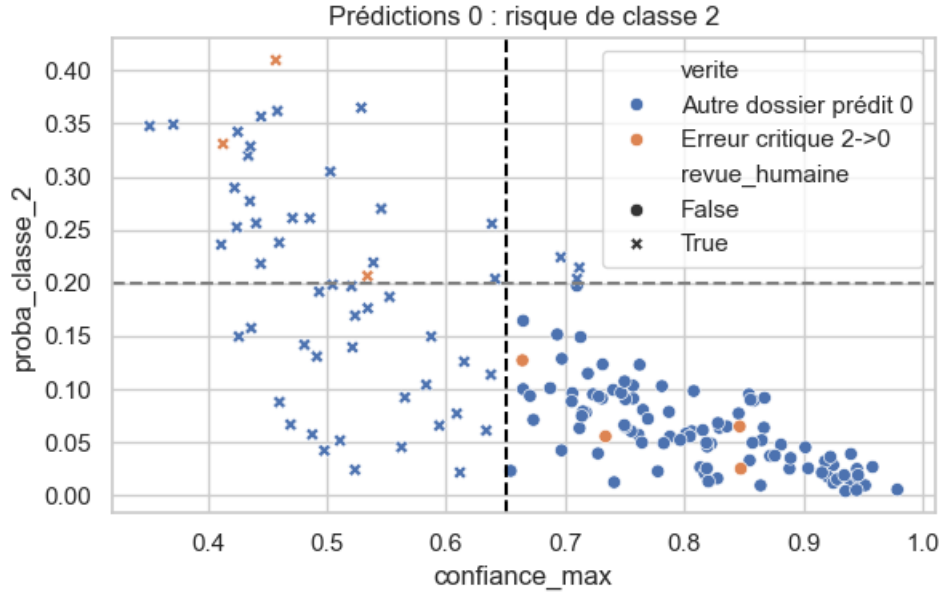
Comment interpréter le fonctionnement du modèle et ses limites pour la communication au client ?

	confiance_max				ecart_top_2				proba_classe_2			
	count	median	min	max	count	median	min	max	count	median	min	max
type_erreur												
0->1	27	0.701	0.413	0.906	27	0.471	0.005	0.850	27	0.084	0.011	0.422
0->2	18	0.528	0.376	0.908	18	0.180	0.007	0.844	18	0.528	0.376	0.908
1->0	42	0.537	0.371	0.904	42	0.234	0.002	0.833	42	0.144	0.022	0.357
1->2	29	0.726	0.356	0.946	29	0.583	0.022	0.900	29	0.726	0.356	0.946
2->0	7	0.664	0.413	0.847	7	0.455	0.047	0.758	7	0.127	0.025	0.410
2->1	14	0.574	0.335	0.869	14	0.302	0.001	0.770	14	0.240	0.039	0.432
correct	263	0.765	0.351	0.987	263	0.608	0.004	0.978	263	0.099	0.004	0.987

revue_humaine	automatique	revue
type_erreur		
0->1	16	11
0->2	4	14
1->0	15	27
1->2	16	13
2->0	4	3
2->1	6	8

	confiance_max	ecart_top_2	proba_classe_2	revue_humaine
0	0.664	0.455	0.127	False
1	0.734	0.523	0.056	False
2	0.413	0.082	0.331	True
3	0.847	0.720	0.025	False
4	0.457	0.047	0.410	True
5	0.534	0.275	0.207	True
6	0.846	0.758	0.065	False





Interprétation client – Message au client

Comment interpréter le fonctionnement du modèle et ses limites pour la communication au client ?



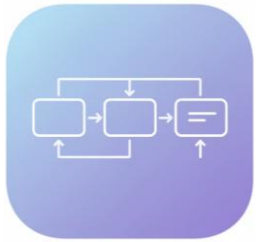
Messages clés

- Le modèle donne un repère, pas un diagnostic
- La vérification humaine est indispensable et ne repère pas tous les cas à risque
- Le conseiller garde la décision finale



Synthèse d'interprétation

- Variables-clés : synthèse d'entretien (57,7%), département (23,7%), code ROME (16,5%), âge (0,5%), statut allocataire (0,3%)
- Profils mal prédits
- Vigilance opérationnelle :



Conclusion scénarios

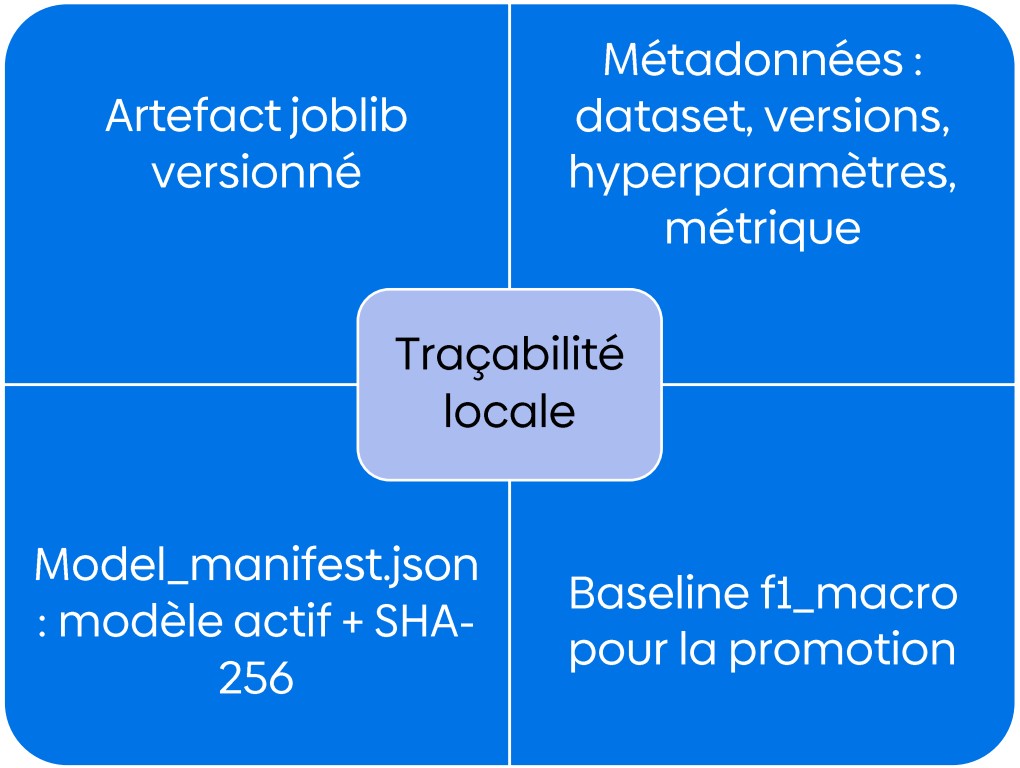
- S1 complet : la meilleur performance (mais variable discriminante)
- S2 : le moins performant
- S3 : le compromis fragile
- S4 : le moins cher (mais variable discriminante)
- S1 hybride : le meilleur compromis

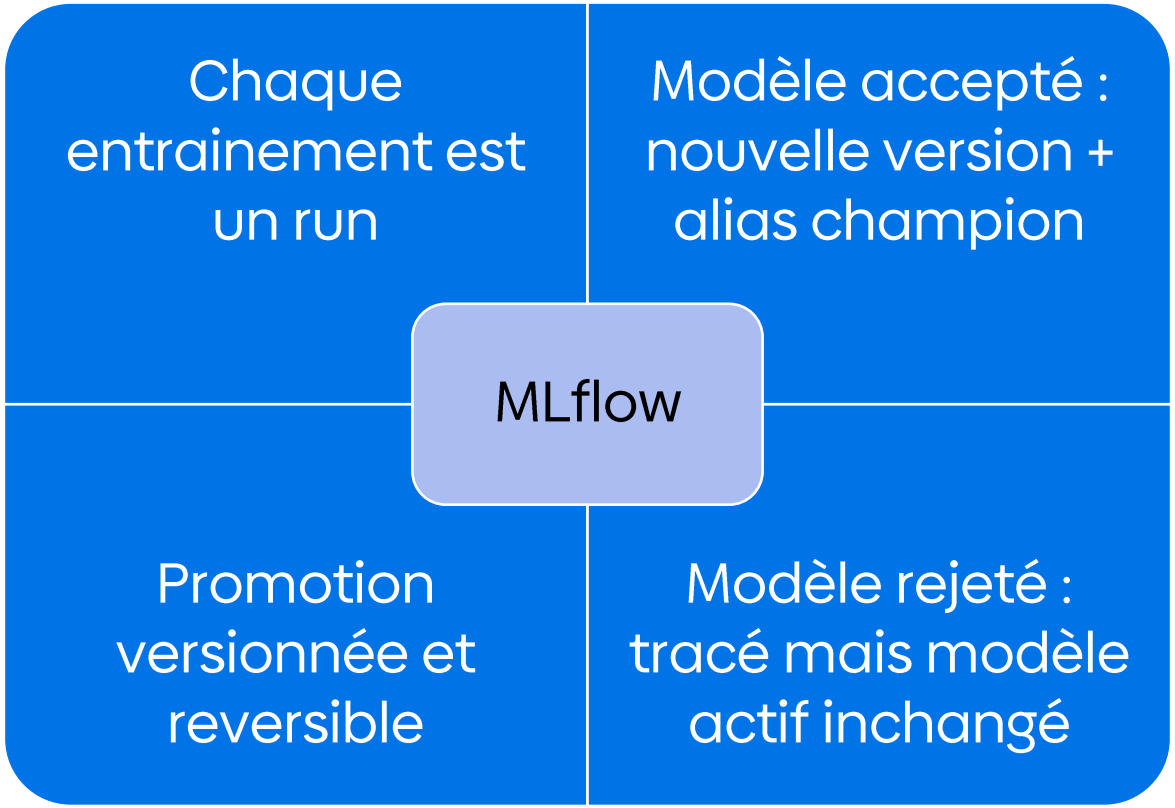
08

Industrialisation

Industrialisation - Persistance et suivi des versions du modèle

Comment sauvegarder, tracer et versionner les modèles ?

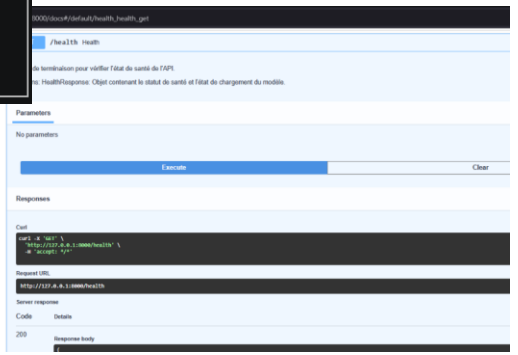




Industrialisation - API de service

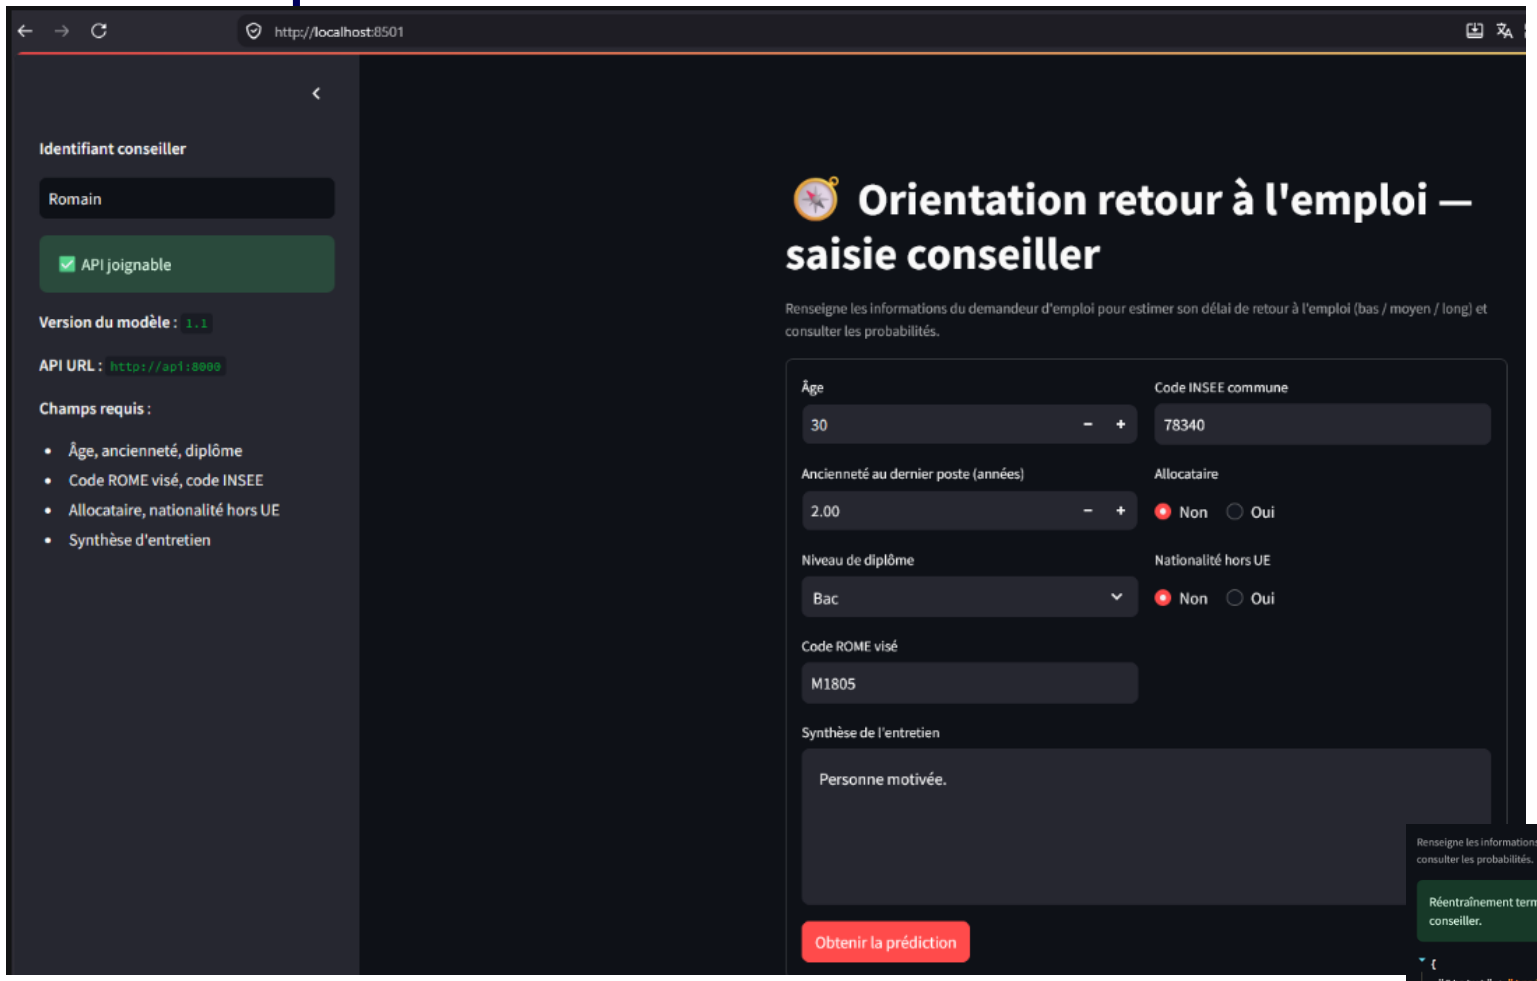
Comment exposer le modèle via une API ?

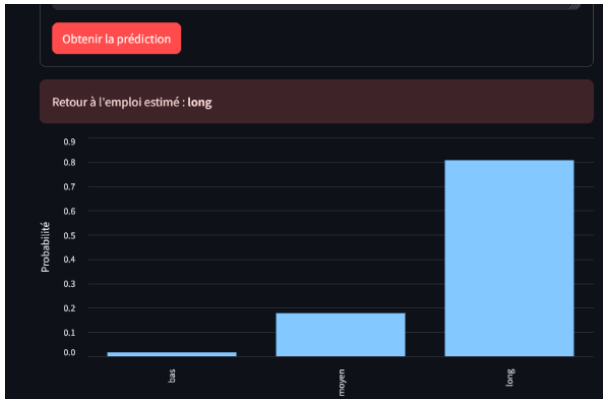
Route	Méthode	Rôle	Réponse nominale	Erreurs principales
`/health`	`GET`	Vérifier que l'API répond et que le pipeline actif, désigné par `model_manifest.json`, est chargé et intègre	`200` avec `status`, `model_loaded` et `model_version`	`status="degraded"` si le modèle est absent, invalide ou impossible à charger
`/predict`	`POST`	Prédire le délai de retour à l'emploi pour un demandeur	`200` avec classe `bas/moyen/long` et probabilités	`422` si le payload est invalide, `503` si le modèle actif est indisponible
`/feedback`	`POST`	Enregistrer la correction d'un conseiller pour le prochain réentraînement	`200` avec statut et nombre total de corrections stockées	`422` si le payload est invalide
`/train`	`POST`	Réentraîner le pipeline, intégrer les feedbacks, comparer le modèle à la baseline et tracer l'entraînement avec MLflow	`200` avec statut (`trained`/`rejected`), métriques, décision de promotion, `model_path`, `artifact_version`, `mlflow_run_id` et `model_version` si le modèle est promu	`404` si le dataset manque, `422` si l'entraînement ou le suivi MLflow échoue
`/history`	`GET`	Consulter l'historique persistant des prédictions, filtrable par conseiller et limité par `limit`	`200` avec la liste des prédictions passées, la plus récente en premier	Liste vide si aucun historique n'existe encore

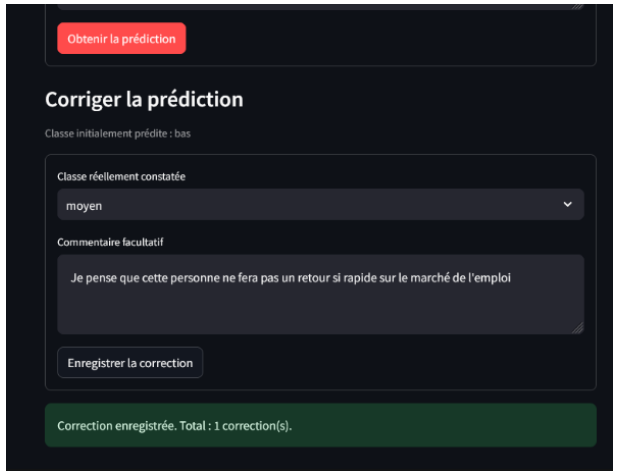


Industrialisation - Interface utilisateur

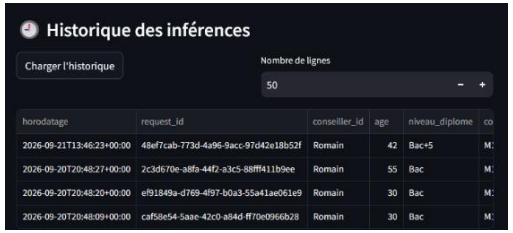
Comment permettre au conseiller d'utiliser le modèle ?





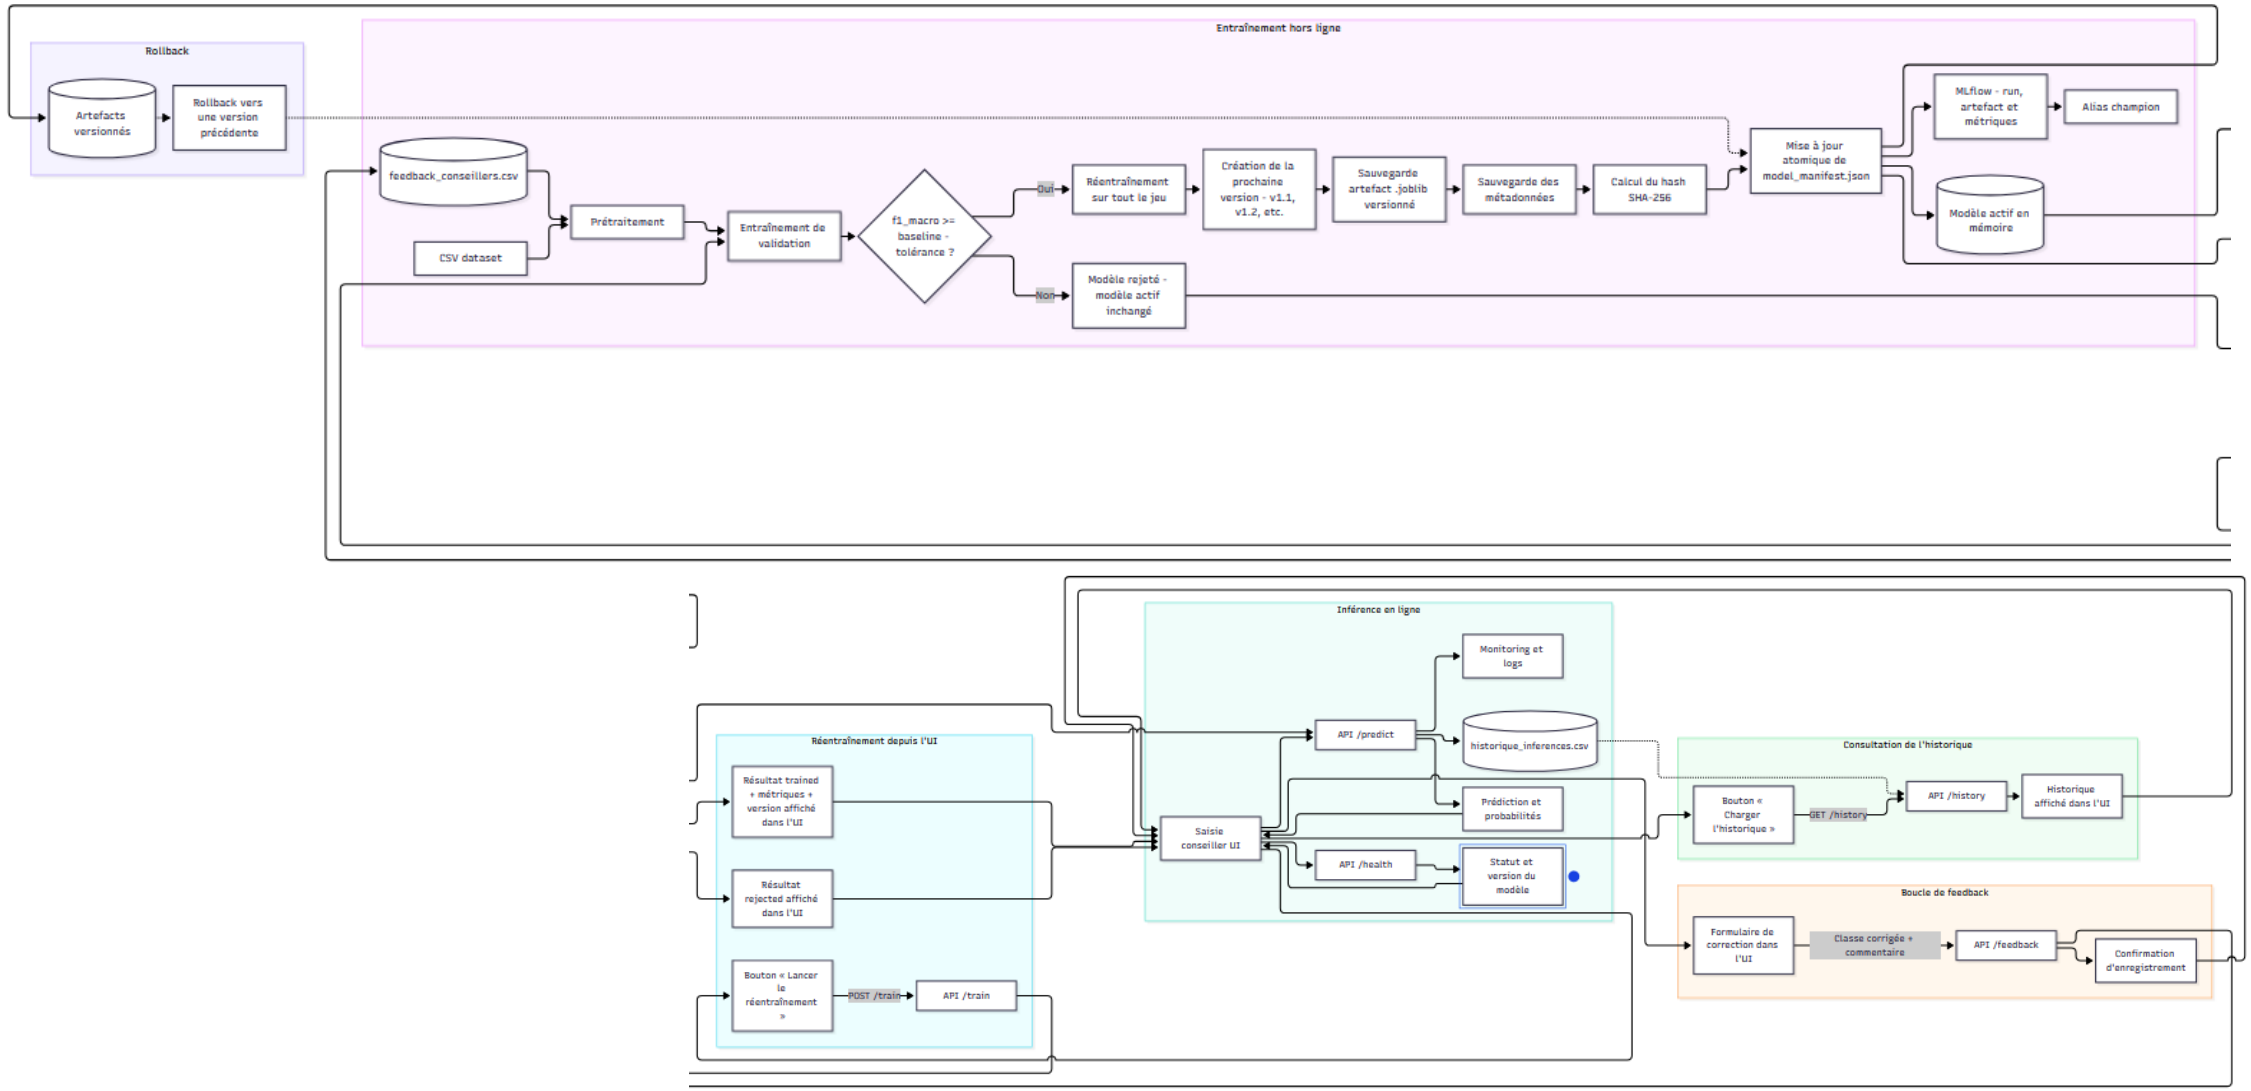






Industrialisation – Schémas d'architecture

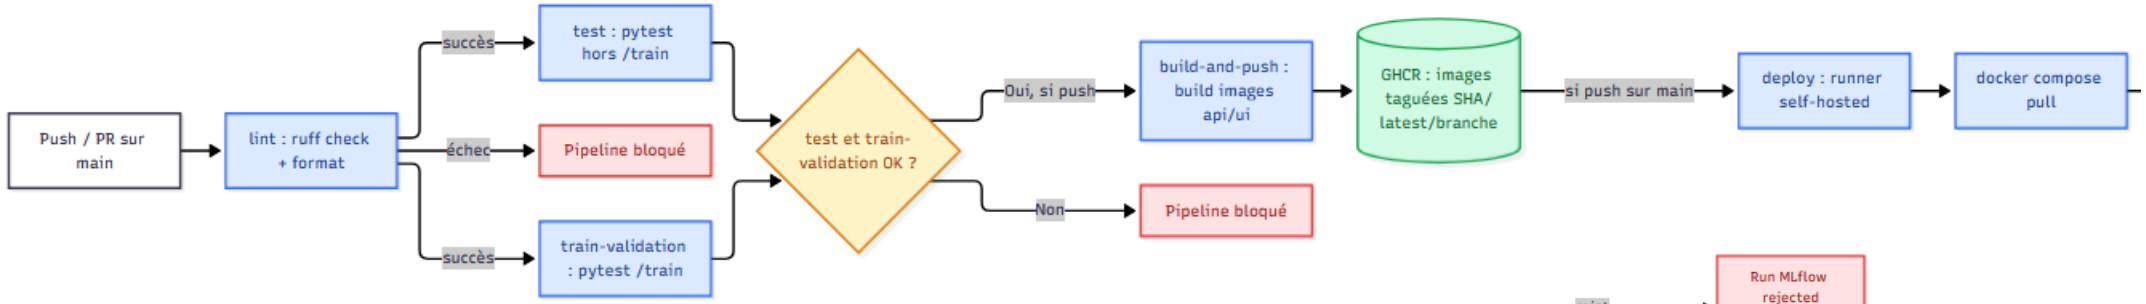
Comment s'articulent l'architecture et les flux de données ?

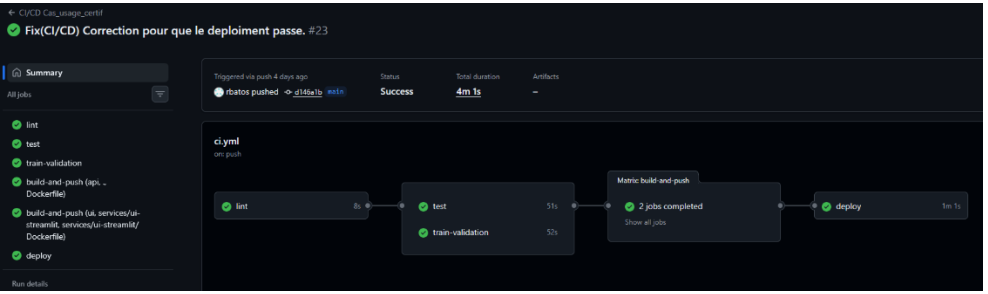


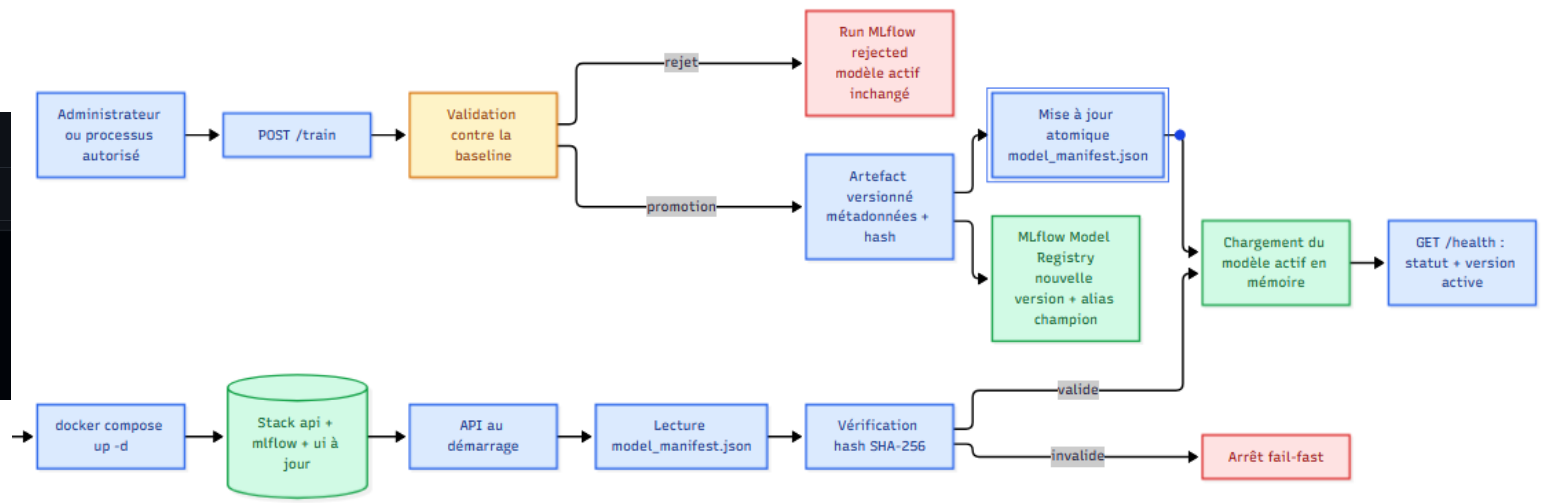
Industrialisation – Conteneurisation & CI/CD

Comment conteneuriser la solution ?

- 2 images :
  - api
  - ui (qui contient mlflow)
- 3 services :
  - Api sur le port 8000
  - Ui sur le port 8501
  - Mlflow sur le port 5000

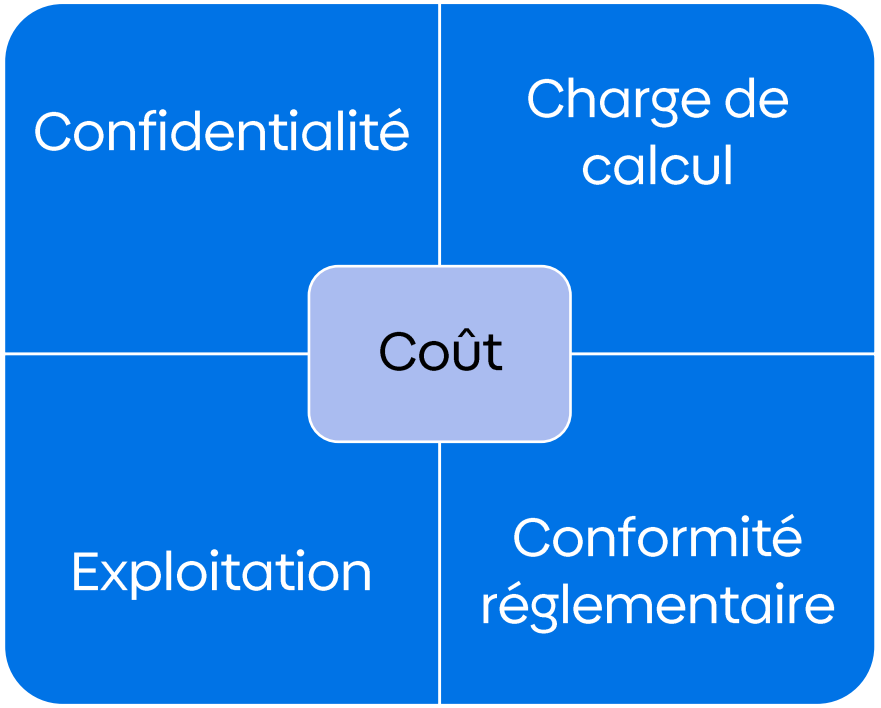


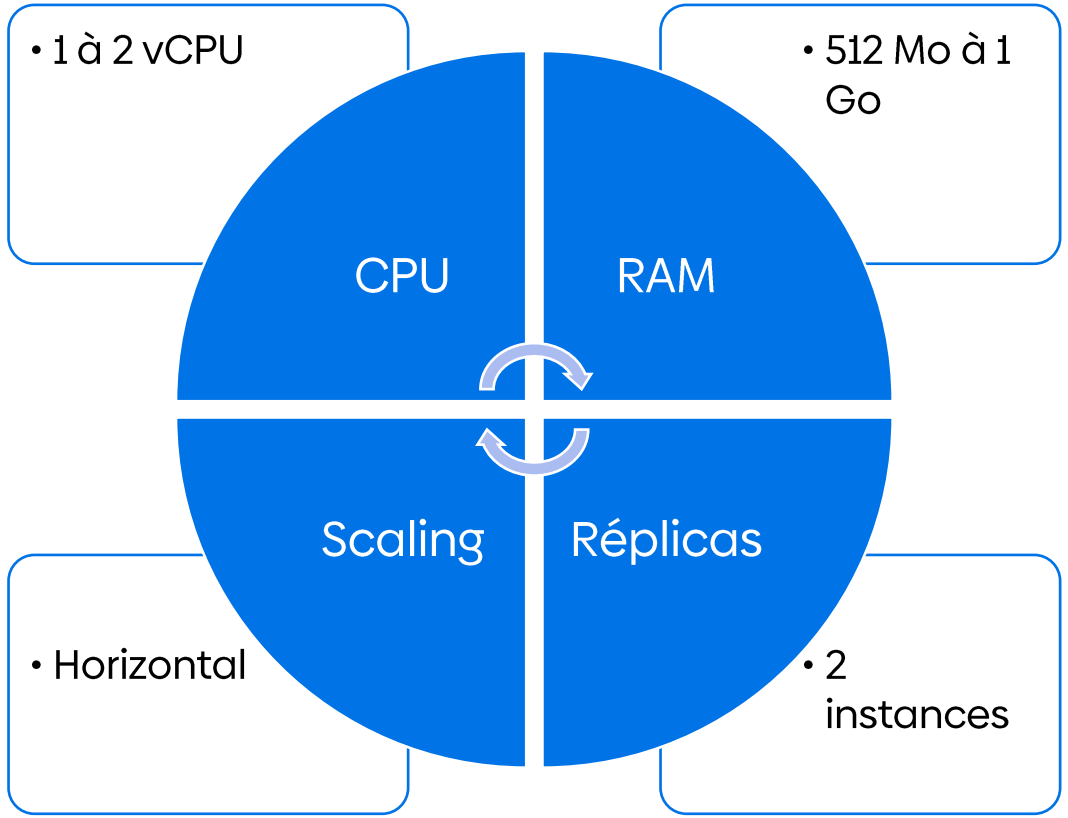




Industrialisation – Performance / Coûts et choix hébergement

Quel hébergement choisir pour tenir la latence cible à moindre coût ?

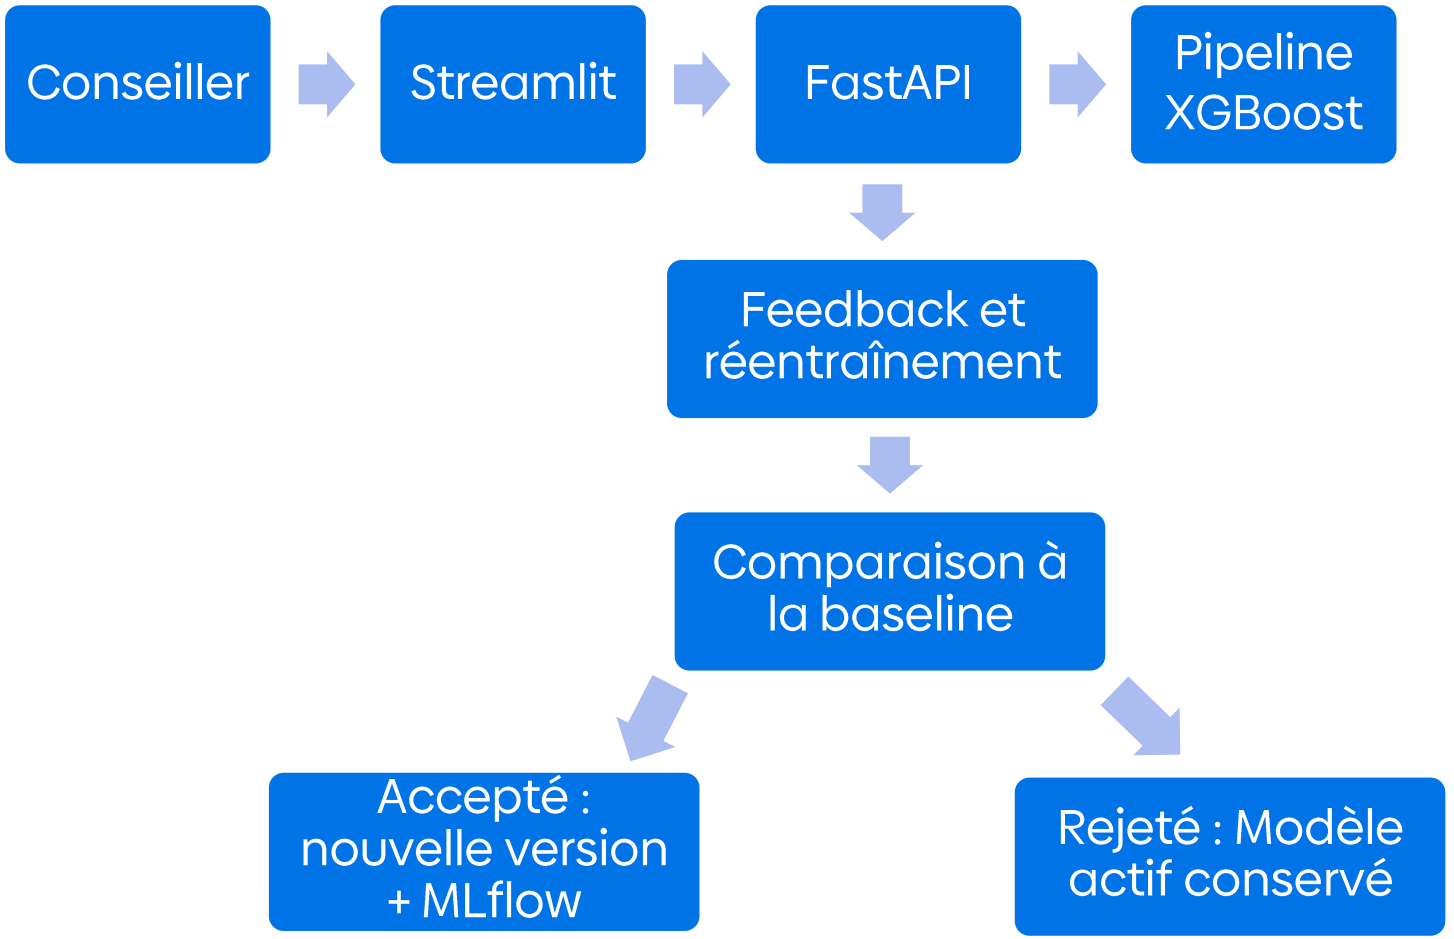




Industrialisation – Choix techniques & Architecture

Pourquoi ces choix techniques ont-ils été retenus ?

- FastAPI
- MLflow
- BGBoost
- Joblib
- Streamlit
- Docker
- Pydantic
- Uvicorn
- Loguru



Industrialisation – Points encore ouverts

Quels prérequis restent à lever avant la mise en production ?



Garde-fou de promotion incomplet



Monitoring opérationnel incomplet



Validation humaine de la promotion absente



Qualité des feedbacks à contrôler



Persistance MLflow non adaptée à la production



Procédure de rollback non validée



Surveillance des dérives non implémentée

09

Suivi en production & amélioration continue

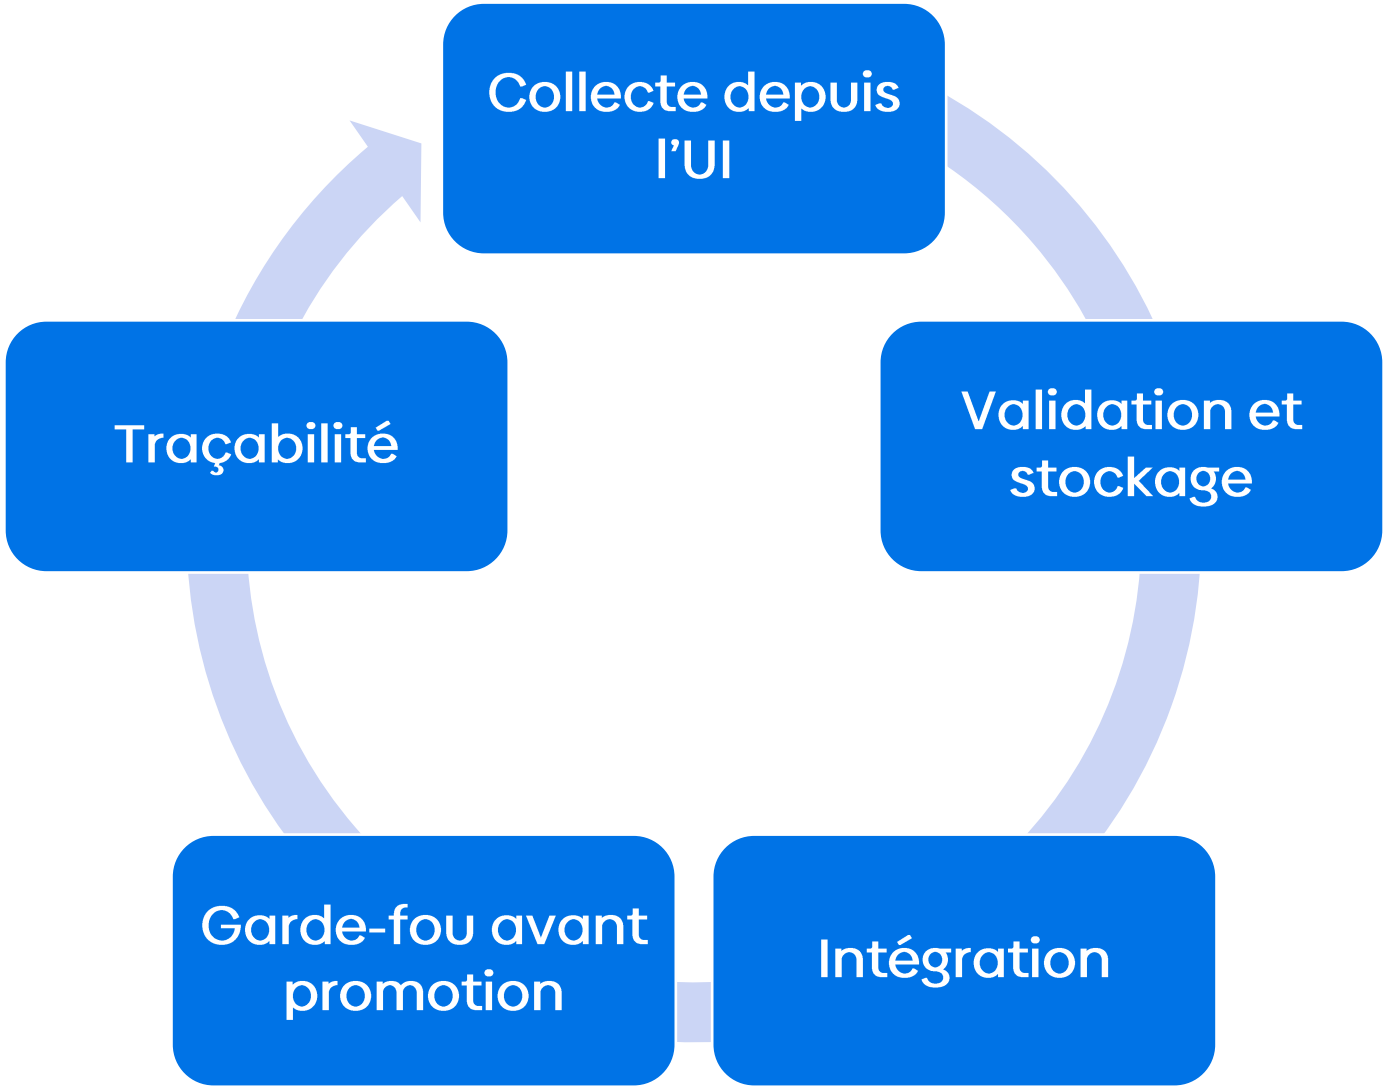
Suivi en production - Métriques à surveiller

Quelles métriques surveiller en production ?

Type	Métrique	Seuil d'alerte	Source
Modèle	`f1_macro` de validation (à chaque `POST /train`)	< baseline - 0,02 (tolérance du garde-fou anti-régression déjà implémenté, `DEGRADATION_TOLERANCE` dans `app/main.py`)	Run MLflow (`log_training_run`) comparé à `models/train_metrics_baseline.json`
Modèle	Taux d'abstention (probabilité max < 0,65 ou écart top-2 < 15 %, cf §7.2)	> 20 % sur 4 semaines glissantes	`data/historique_inferences.csv` (à enrichir d'un champ `abstention`, cf §9.4)
Modèle	Erreurs critiques 2→0 (classe réelle « long » prédite « bas »)	> 0 détectée lors d'un audit mensuel des corrections	`data/feedback_conseillers.csv` (corrections conseillers via `POST /feedback`)
Données	PSI (Population Stability Index) sur `age`, `departement`, `code_rome_vise`, `nationalite_hors_ue` et `est_allocataire`	> 0,2	Batch journalier à mettre en place (non implémenté à ce jour, cf §9.3)
Système	Latence p95 API	> 500 ms (cible fixée en §8.7)	`logs/api.log` (middleware `X-Request-ID`), exportable vers Prometheus
Système	Disponibilité	`GET /health` renvoie `status="degraded"` de façon répétée	`HEALTHCHECK` Docker (`docker-compose.yml`/`docker-compose.prod.yml`)
CI/CD	Échec du job `train-validation` sur push vers `main`	Bloque automatiquement `build-and-push` et `deploy`	GitHub Actions (cf §8.6)

Suivi en production - Boucle de rétroaction

Comment les retours des conseillers servent-ils à améliorer le modèle ?



Suivi en production - Plan de réentraînement & Robustesse

Comment détecter les défaillances du modèle et déclencher un réentraînement maîtrisé ?

- Calendaire
- Volume de nouvelles données
- Performance

Axe	Métrique opérationnelle	État actuel	Action automatique visée
OOD (Out-Of-Distribution)	Score de distance sur les variables numériques clés (`age`, `ancienneté_poste_ans`) par rapport à la distribution du dataset d'entraînement (ex. distance de Mahalanobis ou score d'isolation)	Non implémenté : l'API ne calcule aujourd'hui aucun score de distribution, seule la validation Pydantic (bornes métier) filtre les entrées aberrantes	Ajouter un calcul de score OOD dans `request_to_features` (`app/main.py`), logger les dossiers hors distribution dans `logs/api.log`, et forcer l'abstention (statut « confiance insuffisante ») au-delà d'un seuil à calibrer sur le jeu d'entraînement
Drift du seuil de rejet	Taux d'abstention (probabilité max < 0,65 ou écart top-2 < 15 %) calculé sur une fenêtre glissante de 4 semaines	Le seuil est appliqué au moment de la prédiction (§7.2), mais le taux d'abstention n'est pas encore agrégé ni suivi dans le temps : `data/historique_inferences.csv` ne contient pas de champ dédié	Ajouter un champ `abstention` (booléen) à `historique_inferences.csv` et `HistoryEntry` / `HISTORY_COLUMNS` (`app/main.py`, `app/schemas.py`), puis calculer le taux d'abstention glissant, réviser le seuil de rejet si la dérive dépasse 20 % sur 4 semaines
Calibration	Brier score et courbe de calibration mensuelle sur les prédictions confirmées (dossiers avec feedback conseiller)	Non implémenté : aucune évaluation de calibration n'est réalisée après le déploiement, seul le `log_loss` est mesuré hors ligne lors de la comparaison de modèles (§5.3)	Calculer mensuellement le Brier score à partir des couples (probabilités prédites, classe corrigée dans `data/feedback_conseillers.csv`), recalibrer (Platt, isotonic) sans réentraîner tout le pipeline si seule la calibration dérive

10

Conclusion et questions ouvertes